ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC & KỸ THUẬT MÁY TÍNH



Kho Dữ liệu và Hệ hỗ trợ Quyết định

CO4031 – HK261

Báo cáo Bài tập lớn

Quy trình Thẩm định Tín dụng
Home Credit Default Risk

Giảng viên hướng dẫn: Thạc sĩ Đỗ Thanh Thái

Nhóm sinh viên:

Doãn Phương Hùng Cường	L02 2310381
Nguyễn Thiên Hào	L02 2310853
Nguyễn Khắc Khánh Huy	L02 2311186

THÀNH PHỐ HỒ CHÍ MINH, 14 THÁNG MƯỜI MỘT NĂM2026

Lời cam đoan

Place Holder

Lời cảm ơn

Place Holder

Tóm tắt

Place Holder

Mục lục

I Yêu cầu nghiệp vụ **1**

1 Bối cảnh và bài toán **1**
1.1 Bối cảnh thị trường tài chính tiêu dùng 1
1.2 Thách thức nghiệp vụ và Mâu thuẫn mục tiêu 1
1.3 Định nghĩa bài toán kỹ thuật 2

2 Người dùng và Quyết định cần hỗ trợ **2**

3 KPI **5**

4 Phạm vi và Giả định **5**
4.1 Phạm vi dự án 5
4.2 Nghiệp vụ và Kỹ thuật 6

II Thiết kế Kho dữ liệu và Quy trình ETL **8**

5 Nguồn dữ liệu và Khám phá Dữ liệu (EDA) **8**
5.1 Phân rã Thực thể và Quan hệ Nghiệp vụ 8
5.2 Mức độ Chi tiết (Granularity) và Lược đồ Quan hệ Nguồn 9
5.3 Khám phá Dữ liệu và Tính Toàn vẹn 9

6 Mô hình Đa chiều (Star Schema) **11**
6.1 Sơ đồ Quan hệ Mô hình Đa chiều (Star Schema ERD) 11
6.2 Mức độ Chi tiết (Grain) và Cấu trúc 12

7 Giả định Trục Thời gian **13**
7.1 Ngày Mốc Tham chiếu Cố định (*Anchor Date*) 13
7.2 Thứ nguyên Đóng hai Vai trò (*Role-Playing Dimension*) 13

8 Quy trình ETL và Ánh xạ Dữ liệu **14**

9 Chất lượng Dữ liệu (Data Quality) **17**

III Hiện thực Hệ thống **19**

10 Kiến trúc và Công nghệ **19**
10.1 Tổng quan Kiến trúc Hệ thống 3 Tầng 19
10.2 Kỹ thuật và Cơ chế Vận hành Tối ưu 21
10.3 Luồng Xử lý Truy vấn Tương tác 22

11 Truy vấn Phân tích – Online Analytical Processing **23**
11.1 Không gian Khối Đa chiều và Các Thao tác Phân tích 23
11.2 Kịch bản Truy vấn OLAP Nghiệp vụ 23
11.3 Hiệu năng Truy vấn Thực tế 27

12 Bảng Điều khiển Trực quan Hóa (Dashboard) **28**
12.1 Bộ lọc chung (Global FilterBar) 28
12.2 Tổng quan và Danh mục Tín dụng (Overview & Portfolio) 28
12.3 Phân tích Đa chiều (Multidimensional Drill-down) 31
12.4 Lịch sử Tín dụng Liên ngân hàng (Credit History) 31
12.5 Thám hiểm Dữ liệu Trực tiếp (OLAP Explorer/Pivot View) 33

IV Hệ hỗ trợ quyết định **34**

13 Mô hình dự báo rủi ro **34**

14 Luật thẩm định Green / Yellow / Red **34**

15 Giao diện mô phỏng **34**

V Đánh giá và hướng phát triển **35**

16 Kết quả đạt được **35**

17 Hạn chế **35**

18 Hướng phát triển **35**

19 Phân công công việc **35**

Danh sách hình vẽ

2.1 Luồng Quyết định trong Home Credit . . . 3
5.1 Lược đồ Quan hệ Bộ Dữ liệu Home Credit Nguồn . . . 9
6.1 Sơ đồ Chòm sao Đa chiều (Fact Constellation Schema) . . . 11
8.1 Kiến trúc ETL 5 Giai đoạn Tự động Hóa . . . 14
8.2 Sơ đồ Truy xuất Nguồn Dữ liệu (Data Lineage) . . . 15
10.1 Kiến trúc Hệ thống Tổng thể 3 Tầng . . . 20
10.2 Luồng Xử lý Truy vấn OLAP Tương tác . . . 22
11.1 Khối Đa chiều và Các Thao tác Phân tích Nghiệp vụ . . . 23
12.1 Bảng Điều khiển Tổng quan (Overview Dashboard) . . . 29
12.2 Phân tích Cơ cấu Danh mục Tín dụng (Portfolio Dashboard) . . . 30
12.3 Phân tích Đa chiều Đào sâu Dữ liệu (Drill-down Dashboard) . . . 31
12.4 Phân tích Lịch sử Tín dụng Bureau (Credit History Dashboard) . . . 32
12.5 Công cụ Thám hiểm Khối Dữ liệu Đa chiều Động (OLAP Explorer Dashboard) 33
14.1 Quy trình Thẩm Định . . . 34

Danh sách bảng

2.1 Cấp độ người dùng và Quyết định được hỗ trợ . . . 3
5.1 Kết quả EDA trên Tập Hồ sơ Gốc . . . 10
6.1 Ma trận Quy trình Nghiệp vụ (Bus Matrix) . . . 11
6.2 Quyết định Thiết kế Kiến trúc Kho Dữ liệu . . . 13
8.1 Bảng Ánh xạ Cột Dữ liệu Nguồn sang Kho Dữ liệu Đích . . . 17
9.1 Kết quả Kiểm định Cổng Chất lượng Dữ liệu (Data Quality Report) . . . 18
10.1 Công nghệ Sử dụng trong Hệ thống . . . 21
11.1 Thời gian Phản hồi Truy vấn OLAP . . . 28

List of Listings

1 Truy vấn Phát sinh Chiều Thời gian `dim_time` Tự động . . . 14
2 Trích đoạn Xử lý Làm sạch Dữ liệu . . . 16
3 Truy vấn Hành vi Tín dụng Bureau . . . 17
4 Trích Báo cáo Chất lượng Dữ liệu Tự động . . . 18
5 Truy vấn Roll-up đa cấp theo Độ tuổi và Thu nhập . . . 24
6 Truy vấn CUBE trên Loại hợp đồng và Giới tính . . . 24

7 Truy vấn Drill-down từ Nhóm tuổi sang Nghề nghiệp chi tiết 25
8 Truy vấn Slice, Dice và Pivot Ma trận Lịch sử Tín dụng 26
9 Truy vấn Roll-up Xu hướng Tín dụng theo Năm và Quý 26
10 Truy vấn Xếp hạng Top 3 Nghề nghiệp Rủi ro nhất mỗi Nhóm tuổi 27

Phần I
Yêu cầu nghiệp vụ

1 Bối cảnh và bài toán

1.1 Bối cảnh thị trường tài chính tiêu dùng

Tài chính tiêu dùng đóng vai trò quan trọng trong việc tăng cường thanh khoản thị trường và hỗ trợ nhu cầu tiêu dùng của hộ gia đình. Tuy nhiên, một bộ phận khách hàng mục tiêu của các tổ chức tài chính tiêu dùng như Home Credit là nhóm chưa tiếp cận đầy đủ dịch vụ ngân hàng truyền thống (*unbanked*) hoặc có lịch sử tín dụng hạn chế (*underbanked*). Nhóm khách hàng này thường thiếu báo cáo tín dụng chính thức, tài sản đảm bảo và bằng chứng thu nhập ổn định, khiến việc thẩm định khả năng trả nợ trở nên khó khăn hơn.

Vấn đề này gắn liền với bất đối xứng thông tin trong thị trường tín dụng: người cho vay khó phân biệt khách hàng có khả năng trả nợ tốt với khách hàng có xác suất vỡ nợ cao. Stiglitz và Weiss chỉ ra rằng khi thông tin không đầy đủ, lenders có thể đối mặt với hiện tượng lựa chọn bất lợi (*adverse selection*) và có xu hướng hạn chế cấp tín dụng thay vì chỉ điều chỉnh lãi suất.[SW81]

Trong bối cảnh đó, Home Credit đặt ra bài toán dự đoán khả năng hoàn trả khoản vay của khách hàng dựa trên dữ liệu hồ sơ, lịch sử tín dụng nội bộ và thông tin từ các tổ chức tín dụng bên ngoài. Bộ dữ liệu *Home Credit Default Risk* bao gồm hồ sơ vay, lịch sử tín dụng từ Credit Bureau, số dư thẻ tín dụng, khoản vay POS/cash và lịch sử trả góp, phản ánh tính đa nguồn và đa chiều của dữ liệu tín dụng tiêu dùng.[Hom18]

1.2 Thách thức nghiệp vụ và Mâu thuẫn mục tiêu

Quy trình thẩm định và phê duyệt tín chấp đối mặt với mâu thuẫn giữa mục tiêu mở rộng doanh số và kiểm soát tổn thất tín dụng. Cụ thể, bài toán bao gồm ba thách thức chính:

- **Bất đối xứng thông tin:** Thiếu hồ sơ tín dụng lịch sử và dữ liệu tài chính có thể kiểm chứng làm tăng nguy cơ lựa chọn bất lợi. Khi lender không thể phân biệt đáng tin cậy giữa khách hàng tốt và khách hàng có rủi ro cao, việc mở rộng tín dụng có thể làm gia tăng tỷ lệ vỡ nợ kỳ vọng.[SW81]

- **Chi phí sai lầm bất đối xứng:** Trong phân loại rủi ro tín dụng, việc phê duyệt nhầm một khách hàng có nguy cơ vỡ nợ thường gây tổn thất tài chính lớn hơn chi phí cơ hội khi từ chối nhầm một khách hàng tốt. Do đó, mô hình cần cân bằng giữa khả năng phát hiện

khách hàng rủi ro và việc hạn chế từ chối oan các hồ sơ chất lượng. Các nghiên cứu credit scoring nhấn mạnh rằng hiệu năng phân loại cần được đánh giá cùng tác động nghiệp vụ và tài chính, chứ không chỉ dựa trên một chỉ số dự đoán duy nhất. [LBST15]

- **Độ trễ và tính chủ quan trong vận hành:** Quy trình thẩm định thủ công tốn nhân lực, kéo dài thời gian phản hồi (*Turnaround Time* – TAT) và có thể chịu ảnh hưởng từ đánh giá cảm tính của người thẩm định. Việc tự động hóa phần sàng lọc ban đầu bằng dữ liệu và mô hình dự báo có thể giúp rút ngắn thời gian xử lý, đồng thời tạo cơ sở quyết định minh bạch và có thể kiểm soát.

1.3 Định nghĩa bài toán kỹ thuật

Hệ thống cần giải quyết bài toán tích hợp giữa quản trị dữ liệu và hỗ trợ quyết định tín dụng, gồm hai thành phần chính:

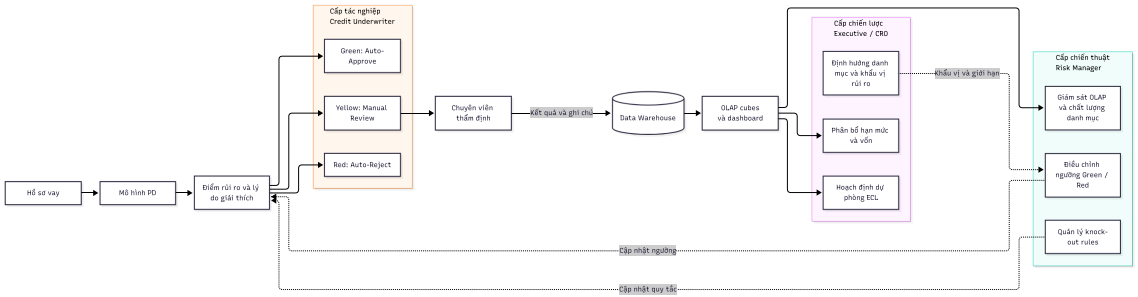
- **Xây dựng Kho dữ liệu tập trung** Chuẩn hóa, làm sạch và tích hợp dữ liệu từ nhiều nguồn, bao gồm thông tin nhân khẩu học, hồ sơ vay, lịch sử tín dụng nội bộ, số dư thẻ, lịch sử trả góp và dữ liệu từ Credit Bureau. Mô hình dữ liệu đa chiều (*dimensional modeling*) được sử dụng để tổ chức dữ liệu quanh các fact table và dimension table, phục vụ phân tích OLAP và báo cáo quản trị. [KR13]

- **Xây dựng Hệ hỗ trợ quyết định** Kết hợp mô hình học máy ước lượng xác suất vỡ nợ (*Probability of Default* – PD) với bộ luật nghiệp vụ phân loại ba mức Green / Yellow / Red. Theo khung Basel, PD là thành phần cốt lõi trong ước lượng rủi ro tín dụng nội bộ, gắn liền với LGD (*Loss Given Default*) và EAD (*Exposure at Default*). [Bas19]

- Hệ thống nhằm tự động hóa bước sàng lọc ban đầu, ưu tiên hồ sơ theo mức độ rủi ro, rút ngắn thời gian xử lý và hỗ trợ kiểm soát tổn thất tín dụng kỳ vọng. Mục tiêu mô hình hóa là dự đoán biến mục tiêu nhị phân: khách hàng gặp khó khăn thanh toán ($TARGET = 1$) hoặc không gặp khó khăn thanh toán ($TARGET = 0$). [Hom18]

2 Người dùng và Quyết định cần hỗ trợ

Hệ thống hỗ trợ quyết định tín dụng phục vụ ba nhóm người dùng chính với nhu cầu thông tin và phạm vi ra quyết định khác nhau: chuyên viên thẩm định tín dụng ở cấp tác nghiệp, quản trị viên rủi ro ở cấp chiến thuật, và ban điều hành hoặc Giám đốc Quản trị rủi ro (*Chief Risk Officer* – CRO) ở cấp chiến lược. Cách phân tầng này phù hợp với nguyên lý của hệ hỗ trợ quyết định: các quyết định tác nghiệp thường mang tính lặp lại và có cấu trúc rõ ràng hơn, trong khi quyết định chiến thuật và chiến lược đòi hỏi phân tích đa chiều, kịch bản và thông tin tổng hợp từ nhiều nguồn. [TSD10]



Hình 2.1: Luồng Quyết định trong Home Credit

Bảng 2.1: Cấp độ người dùng và Quyết định được hỗ trợ

Cấp độ	**Người dùng chính**	**Quyết định cần hỗ trợ**
Tác nghiệp	Credit Underwriter	Phê duyệt, từ chối hoặc chuyển hồ sơ sang thẩm định bổ sung; giải trình các yếu tố rủi ro chính.
Chiến thuật	Credit Risk Manager	Điều chỉnh ngưỡng phân luồng, thiết lập chính sách loại trừ, giám sát chất lượng danh mục và hiệu quả luồng thẩm định.
Chiến lược	Ban điều hành và CRO	Phân bổ hạn mức và vốn theo phân khúc, hoạch định dự phòng rủi ro, định hướng tăng trưởng hoặc thắt chặt danh mục.

Credit Underwriter – Cấp tác nghiệp

Nhu cầu thông tin: Chuyên viên thẩm định cần tiếp cận thông tin tổng hợp về hồ sơ vay và hồ sơ khách hàng, bao gồm thu nhập, tỷ lệ nợ trên thu nhập, lịch sử trễ hạn nội bộ và liên ngân hàng, số dư thẻ, lịch sử trả góp, các yếu tố rủi ro chính chi phối điểm tín dụng, cùng lý do giải thích cho kết quả phân loại của mô hình. Basel Committee yêu cầu quy trình cấp tín dụng phải dựa trên tiêu chí rõ ràng, hiểu biết đầy đủ về hồ sơ rủi ro của người vay và nguồn trả nợ. [Bas25]

Quyết định cần hỗ trợ: Hệ thống phân luồng hồ sơ thành ba nhóm:

1. **Phê duyệt tự động (*Auto-Approve*)**: Hồ sơ có xác suất vỡ nợ ước lượng thấp, đáp ứng các điều kiện chính sách và không có tín hiệu rủi ro nghiêm trọng; có thể được xử lý tự động hoặc phê duyệt theo thẩm quyền được phân cấp.

2. **Từ chối tự động (*Auto-Reject*)**: Hồ sơ có xác suất vỡ nợ vượt ngưỡng chấp nhận được hoặc vi phạm các điều kiện loại trừ cứng, ví dụ lịch sử nợ xấu nặng, tỷ lệ đòn bẩy quá cao

hoặc dấu hiệu gian lận. Quyết định này cần được ghi nhận đầy đủ để phục vụ kiểm toán và giải trình.

3. **Thẩm định thủ công (*Manual Review*):** Hồ sơ nằm trong vùng ranh giới, cần xác minh bổ sung như gọi điện xác nhận, yêu cầu chứng từ thu nhập, kiểm tra thông tin thực địa hoặc xem xét điều chỉnh hạn mức. Đây là luồng quan trọng vì quyết định không thể chỉ dựa hoàn toàn vào điểm số mô hình; người thẩm định cần được cung cấp cả kết quả mô hình và các bằng chứng nghiệp vụ liên quan.

Credit Risk Manager – Cấp chiến thuật

Nhu cầu thông tin: Quản trị viên rủi ro cần các báo cáo phân tích đa chiều (*OLAP cubes*) về chất lượng danh mục, phân phối điểm rủi ro theo nghề nghiệp, khu vực địa lý, loại sản phẩm vay, hạn mức và biến động tỷ lệ quá hạn theo thời gian. Basel Committee nhấn mạnh rằng ngân hàng cần có hệ thống thông tin và kỹ thuật phân tích để đo lường rủi ro tín dụng, giám sát chất lượng danh mục và phát hiện sớm các khoản vay có vấn đề.[Bas25]

Quyết định cần hỗ trợ: Các quyết định chiến thuật bao gồm:

- Điều chỉnh ngưỡng phân luồng τ_{green} và τ_{red} theo chu kỳ thị trường, khẩu vị rủi ro và mục tiêu kinh doanh, nhằm cân bằng giữa doanh số giải ngân và tỷ lệ nợ xấu.
- Thiết lập, cập nhật và kiểm soát các chính sách loại trừ cứng (*knock-out rules*), ví dụ loại trừ hồ sơ có nợ xấu hiện hành, gian lận hoặc khả năng trả nợ không đạt ngưỡng tối thiểu.
- Giám sát hiệu quả của luồng thẩm định thủ công, bao gồm tỷ lệ chuyển đổi, thời gian xử lý, tỷ lệ hồ sơ được phê duyệt sau thẩm định và chất lượng quyết định của luồng Yellow.
- Theo dõi hiệu năng của mô hình PD theo thời gian, đặc biệt là sự suy giảm chất lượng dự báo (*model drift*) và mức độ ổn định của phân phối điểm rủi ro.

Executive/CRO – Cấp chiến lược

Nhu cầu thông tin: Ban điều hành và CRO cần dashboard tổng hợp về chất lượng danh mục, các chỉ số rủi ro theo phân khúc, xu hướng nợ quá hạn, tổn thất kỳ vọng (*Expected Loss* – EL), mức độ tập trung rủi ro và tỷ suất sinh lời trên vốn điều chỉnh theo rủi ro (*Risk-Adjusted Return on Capital* – RAROC). RAROC được sử dụng để so sánh lợi nhuận của hoạt động tín dụng với lượng vốn cần thiết để hấp thụ rủi ro; công thức phổ biến là:

$$\text{RAROC} = \frac{\text{Doanh thu} - \text{Chi phí} - \text{Tổn thất kỳ vọng} + \text{Thu nhập từ vốn}}{\text{Vốn kinh tế}}.$$

Trong đó, tổn thất kỳ vọng thường được ước lượng theo:

$$\text{EL} = \text{PD} \times \text{EAD} \times \text{LGD}.$$ [Tre10]

Quyết định cần hỗ trợ: Các quyết định chiến lược bao gồm:

- Phân bổ hạn mức tăng trưởng tín dụng theo phân khúc khách hàng, khu vực địa lý, sản phẩm và mức độ rủi ro, bảo đảm tăng trưởng nằm trong khẩu vị rủi ro được Ban lãnh đạo phê duyệt.
- Hoạch định quỹ dự phòng rủi ro tín dụng theo chuẩn mực kế toán và quy định của cơ quan quản lý. IFRS 9 yêu cầu ghi nhận tổn thất tín dụng kỳ vọng dựa trên thông tin lịch sử, hiện tại và dự báo tương lai; mô hình này phân biệt tổn thất kỳ vọng 12 tháng với tổn thất kỳ vọng trọn đời tùy theo mức độ suy giảm chất lượng tín dụng. [Int14]
- Định hướng phát triển sản phẩm mới, mở rộng hoặc thắt chặt quy mô cho vay đối với các phân khúc có dấu hiệu suy thoái tín dụng, dựa trên xu hướng quá hạn, PD, tổn thất và mức độ sinh lời điều chỉnh rủi ro.
- Phê duyệt khẩu vị rủi ro, giới hạn tín dụng và chính sách quản trị danh mục. Basel Committee xác định Ban lãnh đạo chịu trách nhiệm phê duyệt và rà soát chiến lược rủi ro tín dụng, trong khi ban điều hành chịu trách nhiệm triển khai các chính sách và quy trình tương ứng. [Bas25]

3 KPI

4 Phạm vi và Giả định

4.1 Phạm vi dự án

Phạm vi dữ liệu

Dự án sử dụng bộ dữ liệu thực nghiệm *Home Credit Default Risk*, bao gồm bảy nhóm bảng quan hệ được liên kết qua mã khách hàng `SK_ID_CURR`:

- `application_train` và `application_test`: dữ liệu hồ sơ tĩnh của mỗi đơn vay, trong đó `TARGET` là biến mục tiêu chỉ có trong tập huấn luyện.
- `bureau` và `bureau_balance`: lịch sử tín dụng ngoài hệ thống và số dư hàng tháng của các khoản vay được báo cáo tới Credit Bureau.
- `previous_application`: lịch sử các đơn vay trước đây của khách hàng tại Home Credit.

- `POS_CASH_balance`: số dư hàng tháng của các khoản vay POS và tiền mặt trước đây tại Home Credit.
- `credit_card_balance`: số dư hàng tháng của thẻ tín dụng trước đây tại Home Credit.
- `installments_payments`: lịch sử thanh toán, bao gồm các kỳ thanh toán đã thực hiện và các kỳ thanh toán bị bỏ lỡ. [Hom18]

Phạm vi chức năng hệ thống

- Thiết kế và triển khai kho dữ liệu đa chiều theo mô hình *Star Schema*, gồm hai bảng sự kiện cốt lõi: `fact_loan_application` và `fact_bureau_credit`, liên kết với sáu bảng thứ nguyên: `dim_customer`, `dim_credit_metrics`, `dim_region`, `dim_contract`, `dim_bureau_category` và `dim_time`.
- Xây dựng đường ống ETL/ELT tự động hóa để trích xuất, làm sạch, biến đổi và tính toán các đặc trưng hành vi cũng như chỉ số tổng hợp.
- Cài đặt các truy vấn OLAP nghiệp vụ phục vụ báo cáo đa chiều về danh mục, phân khúc khách hàng, khu vực, sản phẩm và chất lượng tín dụng.
- Huấn luyện mô hình học máy dự báo xác suất vỡ nợ (PD) và đánh giá năng lực phân loại bằng ROC-AUC, Gini cùng các chỉ số bổ trợ.
- Xây dựng động cơ phân luồng thẩm định (*Triage Engine*) theo ba luồng Green / Yellow / Red và phát triển giao diện mô phỏng hỗ trợ ra quyết định.

Giới hạn ngoài phạm vi

- Không bao gồm nghiệp vụ sau giải ngân, chẳng hạn nhắc nợ, thu hồi nợ xấu tại hiện trường (*Debt Collections*) hoặc xử lý kiện tụng pháp lý.
- Không kết nối API thời gian thực tới hệ thống ngân hàng lõi (*Core Banking*) hoặc Trung tâm Thông tin Tín dụng Quốc gia (CIC) ngoài dữ liệu mô phỏng được cung cấp.
- Không tích hợp giải pháp sinh trắc học chuyên sâu phục vụ nhận diện gian lận khuôn mặt hoặc giả mạo giấy tờ (*Biometric eKYC*).

4.2 Nghiệp vụ và Kỹ thuật

- **Giả định về biến mục tiêu:** Nhãn vỡ nợ TARGET = 1 được định nghĩa theo ngưỡng trễ hạn thanh toán nghiêm trọng từ 90 ngày trở lên (DPD 90+). Nhãn TARGET = 0 tương ứng với khách hàng không phát sinh sự kiện trễ hạn nghiêm trọng trong quan sát.

Bộ dữ liệu Home Credit sử dụng `TARGET` với giá trị 1 cho khoản vay không được trả đúng hạn và 0 cho khoản vay được trả đúng hạn.[Hom18]

- **Giả định về mốc thời gian tham chiếu:** Dữ liệu nguồn Kaggle đã được ẩn danh hóa và biểu diễn trục thời gian dưới dạng số ngày tương đối so với ngày nộp đơn, ví dụ các biến `DAYS_BIRTH`, `DAYS_EMPLOYED` và `DAYS_REGISTRATION`. Hệ thống giả định một ngày mốc tham chiếu cố định (*anchor date*) để quy đổi các mốc thời gian tương đối sang trục thời gian lịch thực tế, phục vụ xây dựng chiều `dim_time` và phân tích theo ngày, tháng, quý, năm.
- **Giả định về tính ổn định của phân phối dữ liệu:** Các đặc trưng hành vi và phân phối nhân khẩu học của khách hàng trong dữ liệu quá khứ được giả định có tính ổn định tương đối và có khả năng khái quát hóa cho các hồ sơ nộp đơn mới. Trong triển khai thực tế, giả định này cần được giám sát thường xuyên bằng các chỉ số phân phối dữ liệu và hiệu năng mô hình.
- **Giả định về chính sách chi phí tổn thất:** Hệ thống ưu tiên giảm thiểu tỷ lệ nợ xấu ở mức chấp nhận được, đồng thời chấp nhận một tỷ lệ hồ sơ thuộc luồng Yellow để xác minh các trường hợp nghi vấn. Chính sách này phản ánh nguyên tắc bảo toàn vốn và cân bằng giữa kiểm soát tổn thất với khả năng tiếp cận tín dụng của khách hàng.

Phần II

Thiết kế Kho dữ liệu và Quy trình ETL

5 Nguồn dữ liệu và Khám phá Dữ liệu (EDA)

Dữ liệu thực nghiệm của hệ thống được trích xuất từ tập dữ liệu công khai Home Credit Default Risk, mô phỏng nghiệp vụ thẩm định tín dụng tiêu dùng cho nhóm khách hàng chưa có hoặc có ít lịch sử tín dụng chính thức (*unbanked/underbanked*). Cấu trúc dữ liệu nguồn là một hệ cơ sở dữ liệu quan hệ phi chuẩn hóa (*denormalized relational structure*) gồm 8 tập tin chính, phản ánh hai nhóm thông tin cốt lõi: dữ liệu tĩnh tại thời điểm nộp đơn và dữ liệu chuỗi thời gian ghi nhận hành vi thanh toán trong quá khứ (*longitudinal/behavioral logs*).

5.1 Phân rã Thực thể và Quan hệ Nghiệp vụ

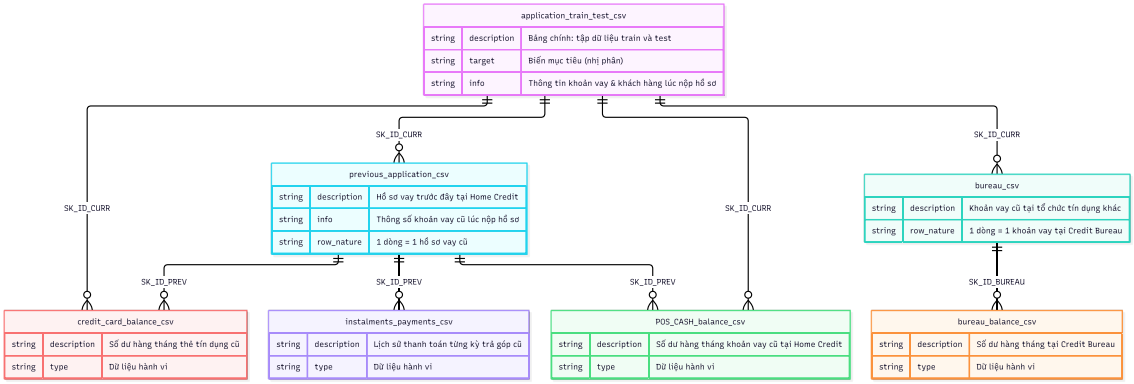
Hệ thống dữ liệu nguồn gồm 8 tập tin quan hệ được tổ chức xoay quanh mã định danh khách hàng `SK_ID_CURR`:

- **Thực thể hạt nhân (`application_{train|test}.csv`)**: Mỗi bản ghi đại diện cho một hồ sơ vay vốn, định danh đơn nhất bằng khóa chính `SK_ID_CURR`. Bảng lưu trữ biến mục tiêu phân loại rủi ro `TARGET` (1 biểu thị khách hàng trễ hạn thanh toán nghiêm trọng, 0 biểu thị khoản vay tất toán đúng hạn) cùng các thuộc tính nhân khẩu học, thu nhập, tình trạng việc làm và thông số khoản tín dụng yêu cầu.
- **Dữ liệu tín dụng liên ngân hàng (Credit Bureau)**:
  - `bureau.csv`: Lưu vết toàn bộ các hợp đồng tín dụng trước đây của khách hàng tại các tổ chức tài chính khác được ghi nhận qua Trung tâm Thông tin Tín dụng. Quan hệ giữa khách hàng và các khoản vay ngoài là quan hệ một–nhiều $(1 : N)$ qua khóa `SK_ID_CURR`.
  - `bureau_balance.csv`: Ghi nhận trạng thái dư nợ và hành vi thanh toán hàng tháng của từng hợp đồng ngoài hệ thống, liên kết với `bureau.csv` thông qua khóa ngoại `SK_ID_BUREAU` $(1 : N)$.
- **Dữ liệu lịch sử nội bộ Home Credit**:
  - `previous_application.csv`: Lưu trữ toàn bộ các hồ sơ vay vốn trong quá khứ của khách hàng tại chính Home Credit, định danh bằng `SK_ID_PREV` và liên kết với bảng trung tâm bằng `SK_ID_CURR` $(1 : N)$.
  - `POS_CASH_balance.csv`: Nhật ký dư nợ hàng tháng của các khoản vay điểm bán (Point of Sale) và tiền mặt trong quá khứ, liên kết qua cặp khóa (`SK_ID_PREV`, `SK_ID_CURR`).

– `installments_payments.csv`: Dữ liệu giao dịch trả nợ thực tế cho từng kỳ thanh toán của các hợp đồng cũ, phản ánh số ngày trễ hạn (`DAYS_INSTALMENT` so với `DAYS_ENTRY_PAYMENT`) và sai lệch số tiền phải trả so với số tiền thực nộp.
– `credit_card_balance.csv`: Biến động số dư và hành vi sử dụng hạn mức thẻ tín dụng hàng tháng của khách hàng trong hệ thống.

5.2 Mức độ Chi tiết (Granularity) và Lược đồ Quan hệ Nguồn

Đặc thù phân rã $1 : N$ đa cấp từ các bảng lịch sử đặt ra yêu cầu kiến trúc cho quy trình ETL/ELT: các bảng hành vi cần được làm sạch, đồng bộ chiều thời gian tương đối và thực hiện kỹ thuật tổng hợp đặc trưng (*aggregation*) trước khi tích hợp vào mô hình đa chiều và các thuật toán dự báo rủi ro tín dụng. Mối quan hệ giữa các thực thể dữ liệu nguồn được mô tả trong Hình 5.1:



Hình 5.1: Lược đồ Quan hệ Bộ Dữ liệu Home Credit Nguồn

5.3 Khám phá Dữ liệu và Tính Toàn vẹn

Trước khi thiết kế kiến trúc kho dữ liệu, nhóm thực hiện phân tích khám phá dữ liệu (EDA) toàn diện trên toàn bộ 356.255 bản ghi ứng dụng và các bảng vệ tinh nhằm phát hiện các dị biệt cấu trúc, giá trị khuyết và bất thường trong thống kê:

1. Mất cân bằng nhãn mục tiêu (*Target Imbalance*): Tập huấn luyện gồm 307.511 hồ sơ, có 282.686 hồ sơ trả nợ đúng hạn (TARGET = 0, chiếm 91,93%) và 24.825 hồ sơ phát sinh nợ xấu nghiêm trọng (TARGET = 1, chiếm 8,07%). Tỷ lệ mất cân bằng xấp xỉ 11,4 : 1 đòi hỏi mô hình phân loại phải sử dụng trọng số hiệu chỉnh lớp (*balanced class weight*) hoặc kỹ thuật lấy mẫu phù hợp để tránh thiên lệch về lớp đa số. Tập kiểm thử gồm 48.744 hồ sơ hoàn toàn để trống nhãn mục tiêu (TARGET = NULL).

2. Dị biệt giá trị Sentinel trong `DAYS_EMPLOYED`: Kiểm tra biến số ngày làm việc ghi nhận 55.374 bản ghi (18,01% tập train) mang giá trị dương cố định 365.243 ngày (khoảng 1.000 năm). Phân tích chéo cho thấy toàn bộ đều thuộc nhóm hưu trí (*Pensioner*) hoặc không có việc làm. Tỷ lệ vỡ nợ của nhóm dị biệt này chỉ là 5,40%, thấp đáng kể so với 8,66% của nhóm đang làm việc bình thường. Quy tắc làm sạch R1 chuyển giá trị 365.243 về `NULL` và flag `is_employed_anomaly = True` để bảo toàn giá trị thông tin nghiệp vụ.

3. Giá trị ngoại lai trong Thu nhập (`AMT_INCOME_TOTAL`): Thu nhập khách hàng có giá trị nhỏ nhất là 25.650, trung vị là 153.000 và trung bình là 170.116. Tuy nhiên, giá trị lớn nhất ghi nhận lên tới 117.000.000 đơn vị tiền tệ. Có 320 bản ghi vượt ngưỡng phân vị 99,9% (900.000). Khi tính toán các tỷ lệ đòn bẩy tài chính như Debt-to-Income (DTI) hay Credit-to-Income (CTI), nếu sử dụng trực tiếp thu nhập ngoại lai sẽ làm sai lệch nghiêm trọng phân phối. Do đó, quy tắc R4 thực hiện cắt ngọn (*capping*) tại ngưỡng phân vị 99,9% trước khi tính các tỷ lệ.

4. Tỷ lệ dữ liệu khuyết thiếu (*Missing Value Analysis*):

- `OCCUPATION_TYPE`: Khuyết 31,44% do người vay không khai báo hoặc làm việc tự do. Được quy đổi về giá trị chuẩn hóa `'Unknown'` (R2).
- `EXT_SOURCE_1..3`: Điểm đánh giá tín dụng chuẩn hóa từ các nguồn dữ liệu ngoài bị khuyết lần lượt là 54,43%, 0,19% và 19,55%. Bằng cách tính giá trị trung bình cộng của các nguồn khả dụng (`ext_source_mean`, quy tắc R8), tỷ lệ khuyết giảm chỉ còn 0,05%.
- `CODE_GENDER`: Có 4 bản ghi bất thường `'XNA'`, chuẩn hóa về `'Unknown'` (R3).

5. Độ bao phủ của dữ liệu lịch sử quan hệ $1:N$: Trong 356.255 người nộp đơn, 305.811 khách hàng (85,8%) có ít nhất một khoản tín dụng được ghi nhận tại Credit Bureau (bình quân 5,6 khoản vay ngoài mỗi khách). Về lịch sử nội bộ, 338.857 khách hàng (95,1%) từng có ít nhất một đơn vay tại Home Credit trong quá khứ, và 339.587 khách hàng có dữ liệu lịch sử thanh toán trả góp. Bảng 5.1 tổng hợp các đặc trưng phân bố chính từ quá trình EDA:

Bảng 5.1: Kết quả EDA trên Tập Hồ sơ Gốc

Thuộc tính	Trung vị	Trung bình	Khuyết/Dị biệt	Xử lý trong Pipeline
`TARGET` (Train)	0	0,0807	0%	Giữ nhãn train (8,07% default).
`DAYS_EMPLOYED`	−1.213	63.815	18,01% sentinel	`is_employed_anomaly`, 365243 →`NULL`.
`AMT_INCOME_TOTAL`	153.000	170.116	320 ngoại lai	Cắt ngọn phân vị 99,9% khi tính DTI.
`OCCUPATION_TYPE`	N/A	N/A	31,44% khuyết	Điền nhãn phân loại `'Unknown'`.
`EXT_SOURCE_1..3`	0,506	0,501	0,05% tổ hợp	Tổng hợp đặc trưng `ext_source_mean`.
`CODE_GENDER`	N/A	N/A	4 dòng `'XNA'`	Chuẩn hóa về `'Unknown'`.

6 Mô hình Đa chiều (Star Schema)

Để đáp ứng yêu cầu phân tích kinh doanh đa chiều, hệ thống chuyển đổi cấu trúc quan hệ chuẩn hóa cao (3NF/denormalized) của dữ liệu nguồn sang mô hình chòm sao sự kiện (*Fact Constellation / Galaxy Schema*) gồm 2 bảng sự kiện (Fact) và 6 bảng thứ nguyên (Dimension).

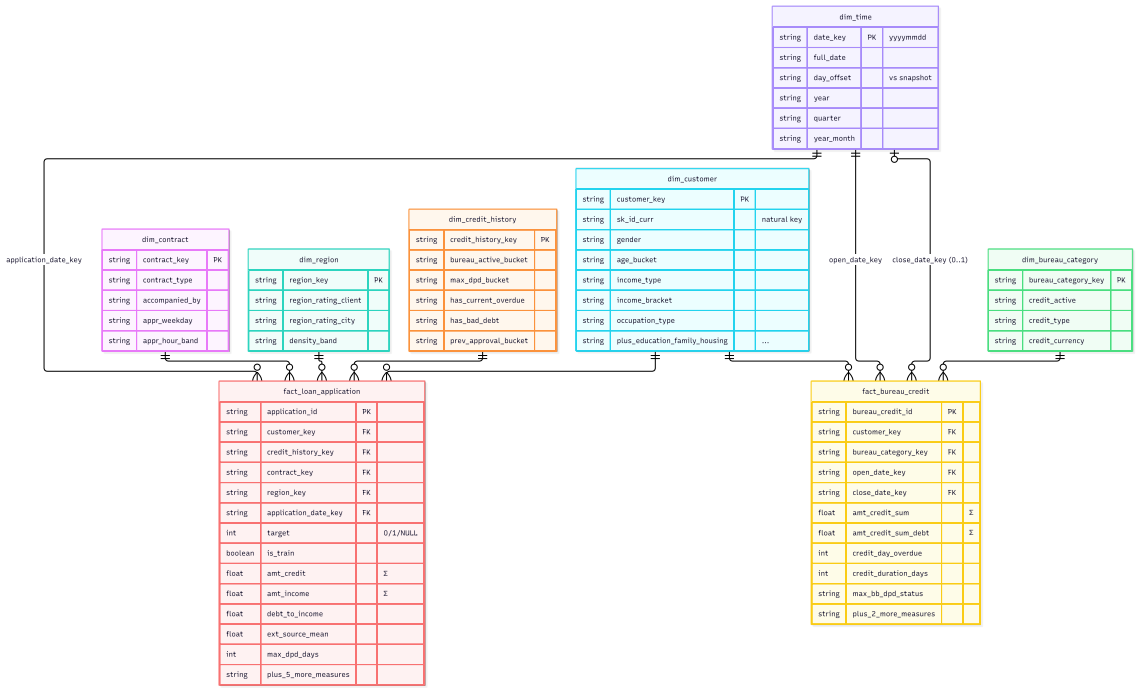
Bảng 6.1: Ma trận Quy trình Nghiệp vụ (Bus Matrix)

	Customer	**History**	**Contract**	**Region**	**Bureau**	**Time**
`fact_loan_application`	✓	✓	✓	✓		✓(Ngày snapshot)
`fact_bureau_credit`	✓				✓	✓×2 (Ngày mở, tất toán)

Hai bảng Fact dùng chung `dim_customer` và `dim_time`, cho phép thực hiện kỹ thuật phân tích liên chiều (*drill-across*). Ví dụ: chuyên viên rủi ro có thể lọc hồ sơ vay theo nhóm tuổi tại `fact_loan_application`, sau đó đối chiếu sang tổng số hợp đồng tín dụng ngoài hệ thống tại `fact_bureau_credit` của cùng nhóm khách hàng thông qua khóa `customer_key`.

6.1 Sơ đồ Quan hệ Mô hình Đa chiều (Star Schema ERD)

Hình 6.1 biểu diễn cấu trúc chi tiết các khóa chính (PK), khóa ngoại (FK) và các trường đo lường (*measures*) của mô hình:



Hình 6.1: Sơ đồ Chòm sao Đa chiều (Fact Constellation Schema)

6.2 Mức độ Chi tiết (Grain) và Cấu trúc

1. Bảng sự kiện `fact_loan_application`:

- **Grain:** Mỗi dòng đại diện cho **một hồ sơ nộp đơn vay vốn** của khách hàng (`SK_ID_CURR`). Bảng chứa toàn bộ 356.255 hồ sơ (gồm 307.511 hồ sơ train và 48.744 hồ sơ test phục vụ DSS).
- **Measures:** Các thước đo tài chính cốt lõi gồm `amt_income_total`, `amt_credit`, `amt_annuity`, `amt_goods_price`, các tỷ lệ tài chính `debt_to_income`, `credit_to_income`, điểm tín dụng `ext_source_mean`, chỉ số hành vi lịch sử `max_dpd_days`, `late_payment_ratio`, `prev_approval_rate`.

2. Bảng sự kiện `fact_bureau_credit`:

- **Grain:** Mỗi dòng đại diện cho **một khoản tín dụng ngoài hệ thống** do Credit Bureau báo cáo (`SK_ID_BUREAU`), bao gồm 1.716.428 bản ghi.
- **Measures:** Quy mô hạn mức `amt_credit_sum`, dư nợ hiện tại `amt_credit_sum_debt`, số tiền đang quá hạn `amt_credit_sum_overdue`, số ngày quá hạn `credit_day_overdue`, và thời hạn khoản vay `credit_duration_days`.

3. Các bảng thứ nguyên (Dimensions):

- `dim_customer`: Thông tin nhân khẩu học (giới tính, nhóm tuổi, học vấn, tình trạng hôn nhân, nhà ở, nghề nghiệp, số con). Quản lý thay đổi theo chuẩn SCD Type 1 do dữ liệu là ảnh chụp tĩnh. Khóa thay thế `customer_key` sinh bằng `ROW_NUMBER()`.
- `dim_credit_history` (Mini-dimension): Lịch sử thô có hàng chục triệu dòng. Kỹ thuật mini-dimension gộp toàn bộ hành vi quá khứ thành 207 hồ sơ định hình sẵn (*binned profiles*) gồm: `bureau_active_bucket`, `max_dpd_bucket`, cờ `has_current_overdue`, cờ `has_bad_debt`, và `prev_approval_bucket`; giúp truy vấn lọc cực nhanh mà không làm phình bảng `dim_customer`.
- `dim_bureau_category` (Junk dimension): Gom tổ hợp 3 thuộc tính phân loại rời rạc gồm trạng thái tín dụng (`credit_active`), loại khoản vay (`credit_type`) và loại tiền tệ (`credit_currency`) thành một bảng duy nhất chỉ 66 dòng, giúp bảng fact tiết kiệm 1,7 triệu chuỗi văn bản lặp lại.
- `dim_contract`: Loại hợp đồng (*Cash loans* / *Revolving loans*), người đi kèm, ngày trong tuần và khung giờ duyệt hồ sơ (401 dòng).
- `dim_region`: Điểm đánh giá khu vực sinh sống và làm việc cùng mật độ dân số (82 dòng).
- `dim_time`: Bảng lịch chuẩn hóa (3.401 dòng ngày) đóng hai vai trò phân tích trên `fact_bureau_credit`.

Bảng 6.2: Quyết định Thiết kế Kiến trúc Kho Dữ liệu

Quyết định	**Căn cứ**
Star Schema thay vì Snowflake	Tối ưu hiệu năng: bảng fact chỉ join 1 lần duy nhất tới mỗi dimension, không tạo thêm tầng chuẩn hóa phụ.
Mini-dimension cho lịch sử tín dụng	Dữ liệu gốc có hơn 27 triệu dòng. Gom thành 207 bucket giúp phân khúc tức thì và giữ bảng khách hàng gọn.
Junk dimension cho Bureau	Gom trạng thái, loại tín dụng và tiền tệ vào bảng 66 dòng; fact chỉ lưu khóa ngoại số nguyên, giảm bộ nhớ đệm và I/O.
Surrogate Key bằng `ROW_NUMBER()`	Cho phép tái sinh hoàn toàn nhất quán khi chạy Full Refresh định kỳ trên tập dữ liệu snapshot.
Full Refresh vào cache	Tính sẵn sàng cao: ETL nạp vào `hc.duckdb.building`, chỉ hoán đổi nguyên tử khi vượt mọi kiểm định chất lượng.

7 Giả định Trục Thời gian

Bộ dữ liệu Home Credit hoàn toàn **không chứa ngày dương lịch thực tế**. Mọi thuộc tính thời gian đều được biểu diễn dưới dạng số ngày hoặc số tháng âm tính lùi từ ngày nộp hồ sơ (*negative offsets*), ví dụ: `DAYS_BIRTH = -15000` (số ngày từ khi sinh đến lúc nộp đơn) hoặc `DAYS_CREDIT = -500` (khoản vay mở trước ngày nộp đơn 500 ngày).

7.1 Ngày Mốc Tham chiếu Cố định (*Anchor Date*)

Để khôi phục trục thời gian lịch thực tế phục vụ phân tích xu hướng đa chiều theo năm, quý, tháng, hệ thống thiết lập một **ngày mốc tham chiếu giả định** trong cấu hình hệ thống (`configs/settings.yaml`): `anchor_date='2018-05-17'`. Ngày lịch thực tế D của bất kỳ biến cố nào được xác định bởi: $D = \text{anchor_date} + \text{offset_days}$.

Hệ quả: Do mọi hồ sơ vay trong `fact_loan_application` được tiếp nhận tại thời điểm nộp đơn, toàn bộ các đơn vay đều mang cùng một khóa ngày `application_date_key=20180517`. Do đó, các phân tích biến động theo chuỗi thời gian được tập trung khai thác trên bảng sự kiện `fact_bureau_credit`.

7.2 Thứ nguyên Đóng hai Vai trò (*Role-Playing Dimension*)

Bảng thứ nguyên `dim_time` được phát sinh bao phủ khoảng thời gian từ 3.000 ngày trong quá khứ đến 400 ngày trong tương lai (3.401 ngày). Bảng này đóng hai vai trò phân tích độc lập trên `fact_bureau_credit`:

- **Ngày mở khoản vay (`open_date_key`):** Bằng anchor_date + `DAYS_CREDIT`. Giá trị này luôn tồn tại và tra cứu chính xác theo `dim_time.day_offset`.
- **Ngày tất toán khoản vay (`close_date_key`):** Bằng anchor_date+`DAYS_ENDDATE_FACT`. Chỉ áp dụng cho các khoản vay đã đóng.

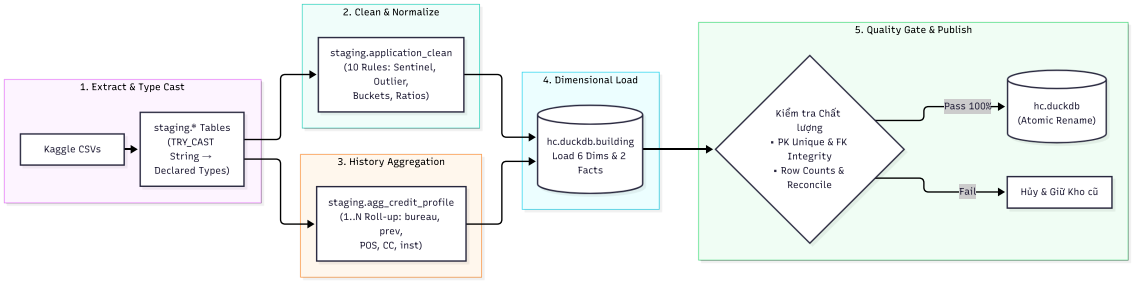
Trong dữ liệu nguồn có một số giá trị `DAYS_ENDDATE_FACT` bất hợp lý (ví dụ: ngày đóng diễn ra trước ngày mở, hoặc giá trị âm vượt quá 40.000 ngày – tương đương hơn 100 năm trước). quy trình ETL xử lý triệt để dị biệt này: nếu ngày đóng không hợp lệ hoặc nằm ngoài dải lịch, hệ thống gán `close_date_key=NULL` thay vì kéo dãn lịch vô lý. Khóa ngoại `close_date_key` cho phép mang giá trị `NULL`, bảo toàn tính toàn vẹn tham chiếu.

```
INSERT INTO dw.dim_time
WITH bounds AS (
    SELECT
        LEAST(-3000, COALESCE((SELECT MIN(days_credit) FROM staging.bureau), 0)) AS lo, 400 AS hi),
offsets AS (SELECT UNNEST(generate_series(lo, hi))::INTEGER AS day_offset FROM bounds),
days AS (SELECT day_offset, DATE '2018-05-17' + day_offset AS d FROM offsets)
SELECT
    CAST(strftime(d, '%Y%m%d') AS INTEGER) AS date_key,
    d                                      AS full_date,
    day_offset,
    quarter(d)                             AS quarter,
    year(d)                                AS year,
    strftime(d, '%Y-%m')                   AS year_month,
    dayofweek(d) IN (0, 6)                 AS is_weekend
FROM days
ORDER BY day_offset;
```

Listing 1: Truy vấn Phát sinh Chiều Thời gian `dim_time` Tự động

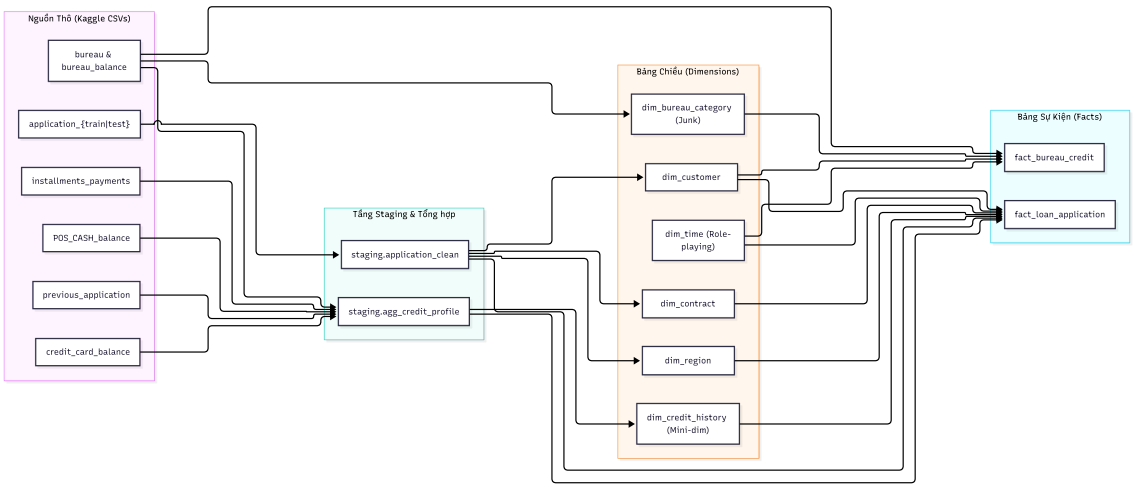
8 Quy trình ETL và Ánh xạ Dữ liệu

Quy trình ETL được cài đặt bằng Python 3.12 (dùng Pandas cho các quy tắc xử lý chuỗi phức tạp và DuckDB SQL cho các tác vụ tổng hợp dữ liệu quy mô lớn), vận hành theo mô hình 5 giai đoạn liên tiếp:



Hình 8.1: Kiến trúc ETL 5 Giai đoạn Tự động Hóa

Sơ đồ dòng chảy dữ liệu (*Data Lineage*) từ 8 tập tin gốc Kaggle qua các bảng Staging trung gian đến các bảng đích trong kho dữ liệu được mô tả chi tiết trong Hình 8.2:



Hình 8.2: Sơ đồ Truy xuất Nguồn Dữ liệu (Data Lineage)

Quy tắc Làm sạch Dữ liệu

Module `src/hcdw/etl/clean.py` triển khai 10 quy tắc chuẩn hóa dữ liệu:

R1 *Xử lý Sentinel:* `DAYS_EMPLOYED = 365243` được gán về `NULL`, bật cờ `is_employed_anomaly=True`.

R2 *Chuẩn hóa Rỗng:* Các chuỗi `'XNA'`, `'XAP'`, rỗng chuyển về nhãn đồng nhất `'Unknown'`.

R3 *Chuẩn hóa Giới tính:* `CODE_GENDER` ngoài tập $\{M, F\}$ được chuyển thành `'Unknown'`.

R4 *Cắt ngọn Thu nhập Ngoại lai:* Khách hàng có thu nhập trên phân vị 99,9% được gắn cờ `is_income_outlier = True`; các tỷ lệ tài chính được tính dựa trên thu nhập đã cắt ngọn.

R5 *Quy đổi Năm:* `age_years=-DAYS_BIRTH/365.25`, `years_employed=-DAYS_EMPLOYED/365.25`.

R6 *Phân khoảng Bucket:* Chia khoảng tuổi $(18-24, 25-34, \dots)$ và khung thu nhập $(< 100k, 100k-150k, \dots)$ theo cấu hình hệ thống.

R7 *Tính Tỷ lệ Đòn bẩy:* `debt_to_income=annuity/income`, `credit_to_income`, `credit_to_goods`.

R8 *Tổ hợp Điểm Tín dụng Ngoài:* `ext_source_mean` là trung bình cộng của các biến `EXT_SOURCE_1..3` có giá trị thực tế.

R9 *Phân nhóm Mật độ & Thời gian:* Sinh `appr_hour_band` và `population_density_band`; đổi các cờ 0/1 sang kiểu boolean chuẩn.

R10 *Chuẩn hóa Hạng Vùng:* Điểm xếp hạng vùng ngoài khoảng 1..3 (tập test có giá trị -1) được đưa về `NULL`.

```python
def clean_application(df: pd.DataFrame, settings: Settings) -> pd.DataFrame:
    cfg = settings.raw["cleaning"]
    sentinel = int(cfg["days_employed_sentinel"])
    out = pd.DataFrame(index=df.index)

    out["sk_id_curr"] = df["sk_id_curr"].astype("int64")
    out["target"] = df["target"].astype("Int64")
    out["is_train"] = df["is_train"].astype(bool)

    # R1: DAYS_EMPLOYED sentinel
    emp = df["days_employed"].astype("float64")
    out["is_employed_anomaly"] = emp == sentinel
    emp_valid = emp.where(~out["is_employed_anomaly"], np.nan)
    out["years_employed"] = (-emp_valid / 365.25).round(1)

    # R4 & R7: Income capping & financial ratios
    income = df["amt_income_total"].astype("float64")
    cap = income.quantile(float(cfg["income_outlier_quantile"]))
    out["is_income_outlier"] = income > cap
    inc_for_ratio = income.clip(upper=cap)
    out["debt_to_income"] = (df["amt_annuity"] / inc_for_ratio).round(4)
    out["ext_source_mean"] = df[["ext_source_1", "ext_source_2",
    ↪  "ext_source_3"]].mean(axis=1).round(4)
    return out
```

Listing 2: Trích đoạn Xử lý Làm sạch Dữ liệu

Gộp $(1 : N)$ tạo Hồ sơ Tín dụng

Các tập tin vệ tinh ghi nhận hàng chục triệu dòng biến động tài chính được tổng hợp về mức độ chi tiết một dòng cho mỗi khách hàng (`SK_ID_CURR`) thông qua truy vấn DuckDB SQL (`10_agg_credit_profile.sql`):

- `bureau_balance` (27,3 triệu dòng) → `agg_bureau_balance` (817.395 dòng): trích xuất trạng thái trễ hạn tối đa `max_status` và số tháng ghi nhận.
- `bureau` (1,7 triệu dòng) → `agg_bureau` (305.811 khách): đếm số khoản vay `Active`, `Bad debt`, tổng dư nợ và tính toán `has_current_overdue` (chỉ xét trên khoản vay đang hoạt động).
- `previous_application` (1,67 triệu dòng) → `agg_previous`: tính tỷ lệ phê duyệt trong quá khứ `prev_approval_rate`.
- `installments_payments` (13,6 triệu dòng) → `agg_installments`: tính tỷ lệ thanh toán trễ hạn `late_payment_ratio` và số ngày trễ tối đa.

```sql
CREATE OR REPLACE TABLE staging.agg_bureau AS
SELECT
    b.sk_id_curr,
    COUNT(*)                                                          AS cnt_bureau_total,
    COUNT(*) FILTER (WHERE b.credit_active = 'Active')                AS cnt_bureau_active,
    COUNT(*) FILTER (WHERE b.credit_active = 'Bad debt')              AS cnt_bureau_bad_debt,
    SUM(CASE WHEN b.credit_active = 'Active' THEN b.amt_credit_sum_debt END) AS sum_active_debt,
    SUM(b.amt_credit_sum_overdue) FILTER (WHERE b.credit_active = 'Active') AS sum_active_overdue,
    MAX(b.credit_day_overdue) FILTER (WHERE b.credit_active = 'Active')     AS max_active_day_overdue,
    MAX(bb.max_status)                                                AS max_bb_status
FROM staging.bureau b
LEFT JOIN staging.agg_bureau_balance bb USING (sk_id_bureau)
GROUP BY b.sk_id_curr;
```

Listing 3: Truy vấn Hành vi Tín dụng Bureau

Bảng 8.1: Bảng Ánh xạ Cột Dữ liệu Nguồn sang Kho Dữ liệu Đích

Nguồn - Kaggle	Đích - Star Schema	Quy tắc & Công thức
SK_ID_CURR	fact.application_id	Khóa tự nhiên định danh hồ sơ đơn vay.
TARGET	fact.target	Giữ nguyên giá trị 0/1 (tập test gán NULL).
AMT_INCOME_TOTAL	dim_customer.income_bracket	Phân khoảng theo cấu hình; cắt ngọn khi tính DTI (R4, R6).
DAYS_BIRTH	dim_customer.age_years	-DAYS_BIRTH / 365.25, phân nhóm tuổi (R5, R6).
DAYS_EMPLOYED	dim_customer.years_employed	Xử lý sentinel 365243 → NULL, cờ is_employed_anomaly.
bureau.DAYS_CREDIT	fact_bureau.open_date_key	anchor_date + DAYS_CREDIT, tra theo dim_time.
DAYS_ENDDATE_FACT	fact_bureau.close_date_key	anchor_date+DAYS_ENDDATE_FACT (gán NULL nếu lỗi).
bureau.CREDIT_ACTIVE	dim_bureau_category.credit_active	Junk dimension; phân loại nợ nạp vào mini-dimension.

9 Chất lượng Dữ liệu (Data Quality)

Để bảo đảm tính toàn vẹn tuyệt đối trước khi công bố dữ liệu vào môi trường phân tích, mô-đun `src/hcdw/etl/quality.py` thực hiện kiểm tra tự động 100% các tiêu chí kỹ thuật và xuất báo cáo chuẩn JSON tại `data/warehouse/dq_report.json`.

Tận dụng khả năng tính toán vector hóa của DuckDB kết hợp tối ưu hóa bộ nhớ trong Pandas, toàn bộ quy trình ETL xử lý 2,6 GB dữ liệu nguồn (58,1 triệu dòng) chỉ mất 11,01 **giây** trên phần cứng máy trạm tiêu chuẩn:

- **Trích xuất (Extract):** 4,36 s (đọc 8 tập tin CSV và ép kiểu qua `TRY_CAST`).
- **Làm sạch (Clean):** 1,15 s (thực thi 10 quy tắc trên 356.255 hồ sơ).

- **Tổng hợp (Aggregate):** 0,64 s (gộp dữ liệu hành vi từ các bảng con).
- **Nạp kho (Load):** 4,73 s (tạo surrogate keys và chèn dữ liệu vào 6 dim, 2 fact).
- **Kiểm định chất lượng (Quality):** 0,13 s (quét toàn bộ ràng buộc PK/FK và đối soát).

Bảng 9.1: Kết quả Kiểm định Cổng Chất lượng Dữ liệu (Data Quality Report)

Nhóm Kiểm định	**Chỉ tiêu**	**State**	**Chi tiết Thực nghiệm**
Khóa chính (PK)	Tính duy nhất & NOT NULL	**ĐẠT**	0 trùng, 0 NULL trên cả 8 bảng DW.
Khóa ngoại (FK)	Toàn vẹn tham chiếu	**ĐẠT**	0 *orphan rows* trên mọi liên kết.
Đầy đủ (Completeness)	Số dòng bảng ứng dụng	**ĐẠT**	Tuyệt đối: 356.255 staging vs 356.255 fact.
	Số dòng hợp đồng Bureau	**ĐẠT**	Tuyệt đối: 1.716.428 staging vs 1.716.428 fact.
Đối soát Tài chính (*Reconciliation*)	Tổng hạn mức	**ĐẠT**	Staging = Fact (= 209.395.079.986).
	Tổng tín dụng Bureau	**ĐẠT**	Staging = Fact (= 609.318.042.486).
Tính logic	Nhãn mục tiêu tập test	**ĐẠT**	0 test chứa `TARGET`.
	Phủ ngày tất toán Bureau	**ĐẠT**	1.079.129/1.079.273 khoản đã đóng có ngày hợp lệ.

```
{
  "run_at": "2026-11-12T00:12:41",
  "timings_sec": {
    "extract": 4.36, "clean": 1.15, "aggregate": 0.64, "load": 4.73, "quality": 0.13
  },
  "data_quality": {
    "passed": true,
    "checks": [
      {"name": "pk_unique:fact_loan_application", "passed": true, "detail": "0 duplicate, 0 null keys"},
      {"name": "fk:fact_loan_application.customer_key->dim_customer", "passed": true, "detail": "0 orphan rows"},
      {"name": "completeness:applications", "passed": true, "detail": "staging 356255 vs fact 356255"},
      {"name": "reconcile:sum_amt_credit", "passed": true, "detail": "staging 209,395,079,986 vs fact 209,395,079,986"}
    ]
  }
}
```

Listing 4: Trích Báo cáo Chất lượng Dữ liệu Tự động

Toàn bộ các phép kiểm tra đạt tỷ lệ chính xác 100%, bảo đảm độ tin cậy tuyệt đối cho mô hình máy học và hệ thống báo cáo điều hành ở các chương tiếp theo.

Phần III

Hiện thực Hệ thống

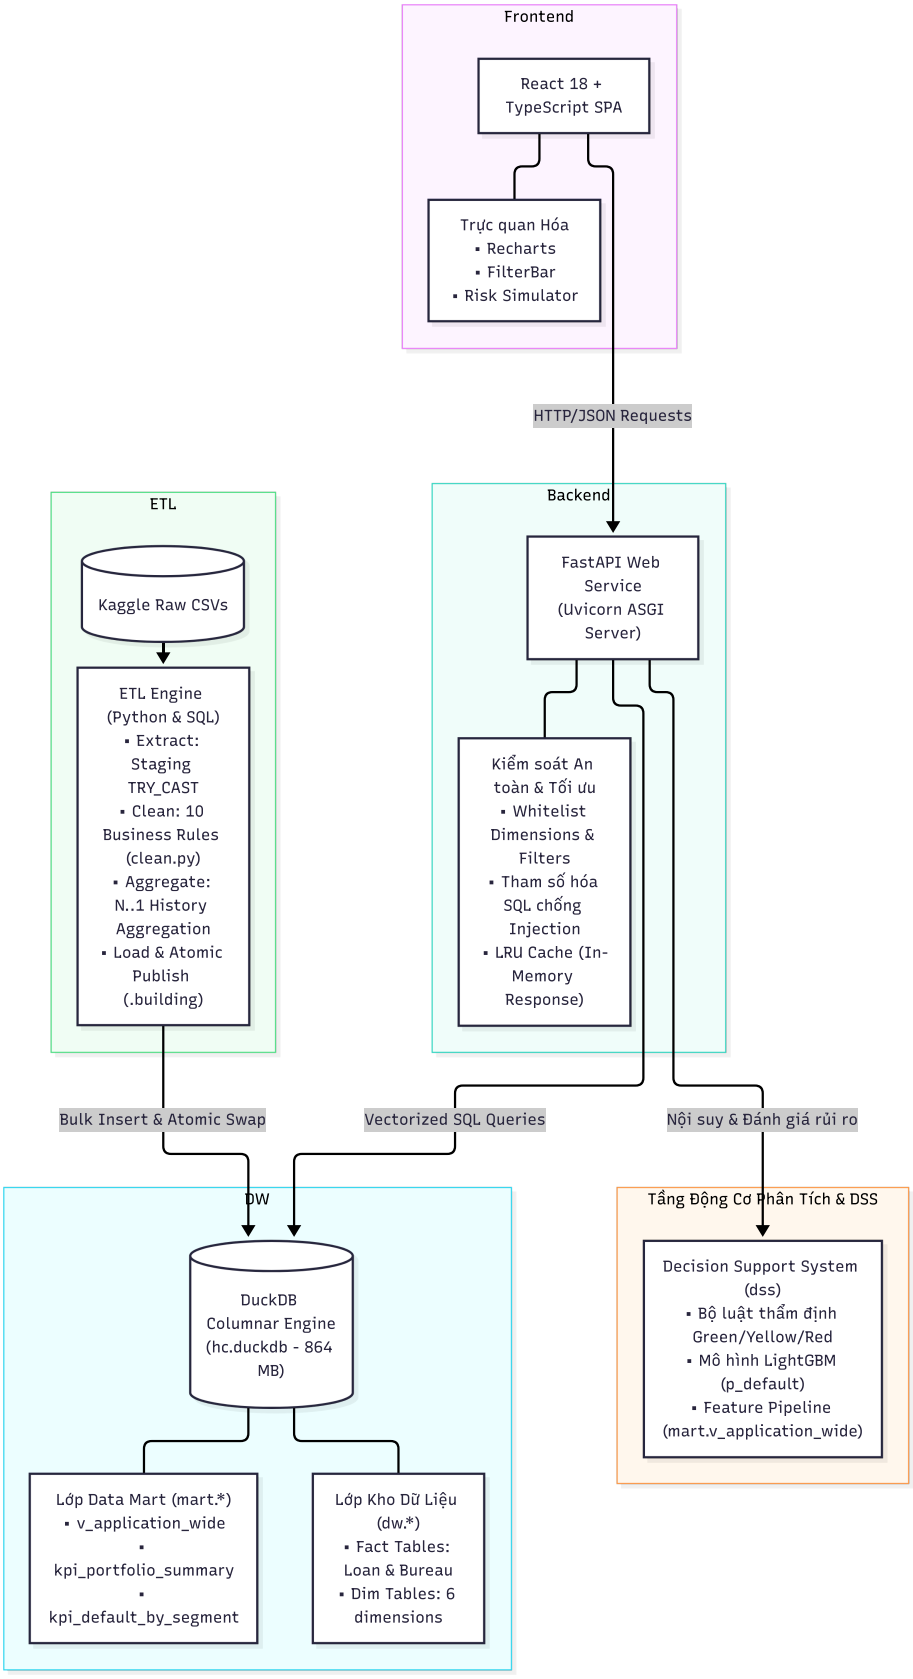
10 Kiến trúc và Công nghệ

Hệ thống được thiết kế theo kiến trúc phân tầng dịch vụ (*three-tier service-oriented architecture*) phân tách rành mạch giữa tầng lưu trữ dữ liệu phân tích, tầng logic nghiệp vụ/API trung gian và tầng giao diện hiển thị tương tác. Kiến trúc này giải quyết triệt để bài toán xử lý khối lượng dữ liệu lớn (hơn 356.000 hồ sơ khách hàng và 1,7 triệu bản ghi tín dụng ngoài), đồng thời bảo đảm độ trễ phản hồi truy vấn đạt mức mili-giây phục vụ thao tác trực quan theo thời gian thực của chuyên viên phân tích.

10.1 Tổng quan Kiến trúc Hệ thống 3 Tầng

Hệ thống gồm 5 chức năng chính được tổ chức thành các tầng độc lập như Hình 10.1:

- **Tầng Thu thập và Chuyển đổi (ETL Engine):** Trích xuất dữ liệu thô từ Kaggle (2,6 GB gồm 8 tập tin CSV), thực thi 10 quy tắc làm sạch dữ liệu nghiệp vụ bằng thư viện tối ưu và chuyển đổi các bảng quan hệ $1 : N$ thành các chỉ số tổng hợp cấp độ khách hàng bằng DuckDB SQL.
- **Tầng Lưu trữ và Động cơ OLAP (DuckDB Warehouse):** Sử dụng hệ quản trị cơ sở dữ liệu phân tích nhúng DuckDB dưới dạng tập tin đơn nhất (`hc.duckdb`, dung lượng xấp xỉ 864 MB). DuckDB áp dụng cơ chế xử lý dữ liệu theo cột (*columnar-vectorized execution*), loại bỏ hoàn toàn chi phí truyền thông liên tiến trình (*IPC overhead*) và tối ưu hóa tính toán cho các hàm tổng hợp đa chiều.
- **Tầng Dịch vụ và Xử lý Nghiệp vụ (FastAPI Backend):** Đóng vai trò cầu nối trung gian, chịu trách nhiệm tiếp nhận yêu cầu từ trình duyệt, thẩm định danh sách trắng (*whitelist validation*) để phòng chống tấn công chèn mã SQL, tham số hóa các điều kiện lọc và duy trì bộ nhớ đệm kết quả truy vấn nội bộ (*LRU cache*).
- **Tầng Động cơ Hỗ trợ Quyết định (Decision Support Engine):** Tích hợp mô hình học máy phân lớp rủi ro LightGBM cùng bộ luật thẩm định đa tầng (Green / Yellow / Red), cho phép đánh giá tức thì điểm tín dụng của một hồ sơ mô phỏng.
- **Tầng Trình diễn (React SPA Frontend):** Ứng dụng đơn trang xây dựng trên nền tảng React 18, TypeScript và Tailwind CSS, tích hợp thư viện biểu đồ Recharts và các sơ đồ kiến trúc động.



Hình 10.1: Kiến trúc Hệ thống Tổng thể 3 Tầng

10.2 Kỹ thuật và Cơ chế Vận hành Tối ưu

Để bảo đảm tính ổn định và an toàn khi vận hành trong môi trường thực nghiệm tài chính, hệ thống cài đặt các cơ chế kỹ thuật cốt lõi sau:

1. **Cơ chế Triển khai Nguyên tử:** Trong quá trình tái cấu trúc hoặc làm mới dữ liệu (Full Refresh), quy trình ETL không ghi trực tiếp lên tập tin dữ liệu đang phục vụ mà xuất kết quả vào một tập tin tạm thời `hc.duckdb.building`. Chỉ khi toàn bộ các bước trích xuất, làm sạch, tính toán mart và vượt 100% các bài kiểm tra chất lượng (*Data Quality Gates*), hệ thống mới thực hiện đổi tên tập tin nguyên tử (*atomic rename*) để thay thế kho dữ liệu đang chạy. Nếu xảy ra lỗi giữa chừng, tập tin cũ hoàn toàn không bị ảnh hưởng, loại trừ nguy cơ hỏng kho dữ liệu.

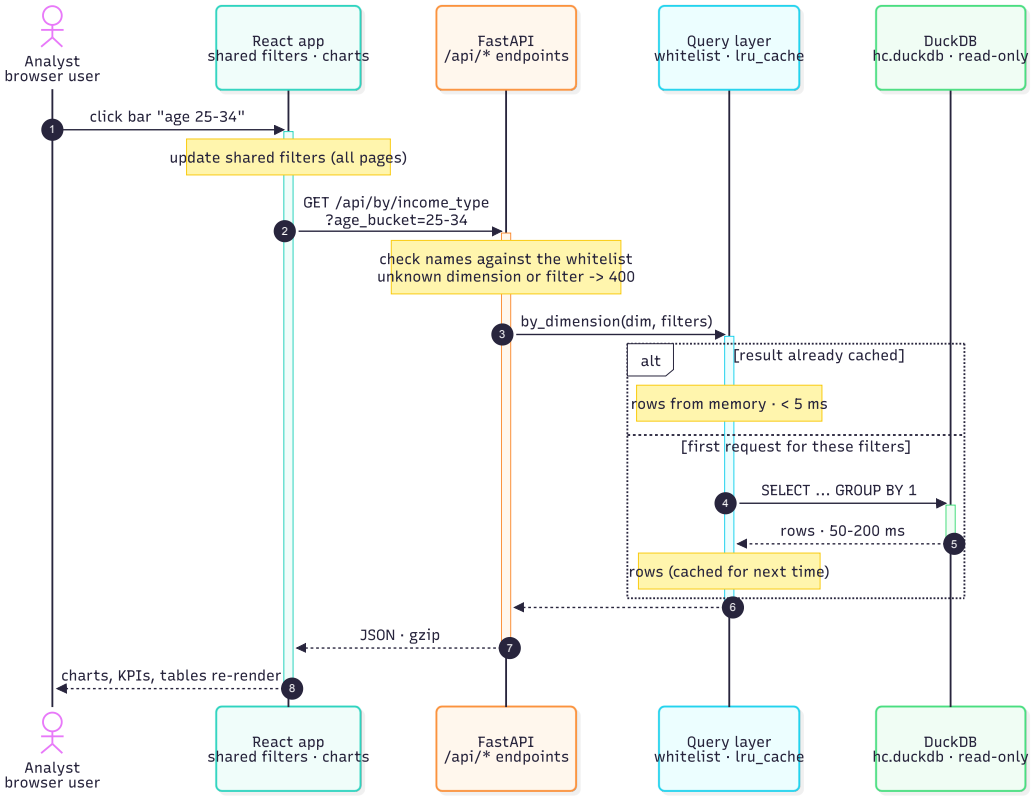
2. **An toàn Truy vấn và Chống SQL Injection:** Trình duyệt và người dùng tuyệt đối không gửi trực tiếp các chuỗi truy vấn SQL thô về máy chủ. Lớp API tại `src/hcdw/api/app.py` và `queries.py` thực hiện xác thực mọi tham số truy vấn thông qua tập danh sách trắng cố định `DIMENSIONS` và `MEASURES`. Bất kỳ tham số lạ nào đều bị từ chối với mã lỗi HTTP 400. Toàn bộ các giá trị lọc được đưa vào câu truy vấn thông qua các tham số gán (*parameterized bindings* dạng `?`), ngăn chặn triệt để nguy cơ tiêm mã độc.

3. **Bộ nhớ Đệm Tầng Truy vấn:** Do dữ liệu kho là một snapshot, kết quả của một phép toán tổng hợp tương ứng với một bộ lọc cố định là bất biến cho đến kỳ ETL kế tiếp. Lớp truy vấn tích hợp bộ nhớ đệm LRU Cache: các truy vấn lặp lại được load trực tiếp từ RAM với độ trễ < 5 ms, trong khi các truy vấn phân tích quét trên 356.000 bản ghi lần đầu chỉ mất từ $15 - 60$ ms.

Bảng 10.1: Công nghệ Sử dụng trong Hệ thống

Tầng Kiến trúc	**Công nghệ Cốt lõi**	**Vai trò & Chức năng Nghiệp vụ**
Kho dữ liệu (DW)	DuckDB 1.1+, SQL	Lưu trữ cột, xử lý vector hóa, quản trị các bảng Fact và Dim.
Quy trình ETL	Python 3.12, Pandas, Typer	Trích xuất CSV, xử lý dị biệt dữ liệu, quản lý CLI tự động hóa.
Dịch vụ Backend	FastAPI, Uvicorn, Pydantic	Cung cấp RESTful API, kiểm soát an toàn truy vấn, bộ nhớ đệm LRU.
Giao diện Người dùng	React 18, TypeScript, Vite	Giao diện tương tác trực quan hóa, đồng bộ bộ lọc dùng chung.
Trực quan hóa	Tailwind CSS, Recharts	Xây dựng đồ thị phân phối, biểu đồ nhiệt và bảng điều khiển động.
Hỗ trợ Quyết định	LightGBM, Scikit-learn	Động cơ phân loại nhị phân và ước lượng xác suất vỡ nợ $p(\text{default})$.

10.3 Luồng Xử lý Truy vấn Tương tác



Hình 10.2: Luồng Xử lý Truy vấn OLAP Tương tác

Mỗi tương tác lọc hoặc phóng to/thu nhỏ trên bảng điều khiển kích hoạt một chu trình xử lý khép kín. Hình 10.2 minh họa chi tiết tuần tự các bước truyền thông từ trình duyệt đến cơ sở dữ liệu:

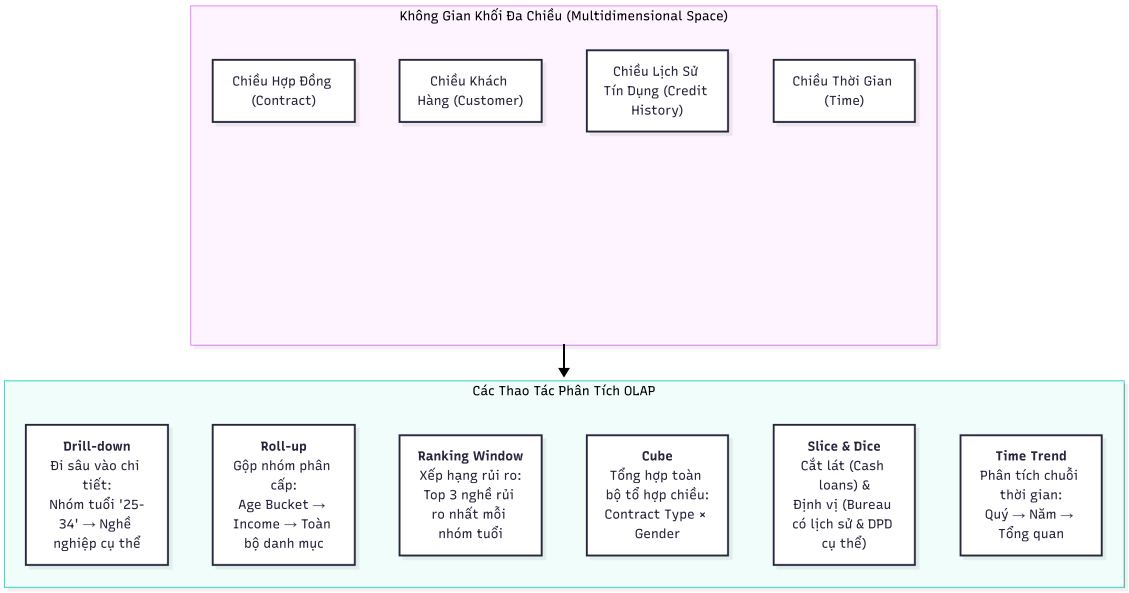
1. Chuyên viên phân tích thao tác nhấp chuột trên một thành phần biểu đồ (ví dụ: cột độ tuổi `25-34`).
2. React cập nhật trạng thái `sharedFilters` và phát lệnh gọi HTTP GET tới endpoint `/api/by/income_type?age_bucket=25-34`.
3. FastAPI xác thực các tham số đối chiếu với danh sách trắng cho phép.
4. Bộ điều phối truy vấn kiểm tra bộ đệm nội bộ: nếu đã tồn tại, dữ liệu được nén Gzip và trả về ngay (< 5 ms); nếu là bộ lọc mới, hệ thống kích hoạt câu lệnh SQL vector hóa xuống DuckDB ($15 - 60$ ms) rồi lưu vào cache.
5. Trình duyệt nhận kết quả dạng JSON và tái render thời toàn bộ các biểu đồ liên quan.

11 Truy vấn Phân tích – Online Analytical Processing

Để phục vụ nhu cầu ra quyết định của các cấp quản trị rủi ro, hệ thống cung cấp các mẫu truy vấn phân tích đa chiều chuẩn hóa trên cơ sở dữ liệu DuckDB thông qua View tầng Mart (`mart.v_application_wide`) và các bảng Fact/Dimension liên kết.

11.1 Không gian Khối Đa chiều và Các Thao tác Phân tích

Khối dữ liệu phân tích tín dụng được cấu thành từ 5 chiều nghiệp vụ cốt lõi: Chiều Khách hàng (`dim_customer`), Chiều Lịch sử Tín dụng (`dim_credit_history`), Chiều Hợp đồng (`dim_contract`), Chiều Địa lý (`dim_region`) và Chiều Thời gian (`dim_time`). Mối quan hệ giữa không gian khối đa chiều và 6 thao tác phân tích nền tảng được cài đặt trong hệ thống như sau:



Hình 11.1: Khối Đa chiều và Các Thao tác Phân tích Nghiệp vụ

11.2 Kịch bản Truy vấn OLAP Nghiệp vụ

Kịch bản 1: Roll-up Phân cấp theo Độ tuổi và Thu nhập

Mục đích: Cho phép Credit Risk Manager quan sát tỷ lệ vỡ nợ bình quân và quy mô tín dụng từ mức chi tiết từng tổ hợp (Nhóm tuổi × Khung thu nhập) lên các cấp độ tổng phụ (*subtotal*) của từng nhóm tuổi và cấp tổng thể toàn danh mục (*grand total*).

Hiện thực: Kết hợp hàm `GROUPING()` với toán tử `GROUP BY ROLLUP (age_bucket, income_bracket)` để nhận diện dòng tổng phụ và gán nhãn `'ALL'`:

```sql
SELECT
    CASE WHEN GROUPING(age_bucket) = 1 THEN 'ALL' ELSE age_bucket END         AS age_bucket,
    CASE WHEN GROUPING(income_bracket) = 1 THEN 'ALL' ELSE income_bracket END AS income_bracket,
    COUNT(*)                          AS n_applications,
    ROUND(AVG(target) * 100, 2)       AS default_rate_pct,
    ROUND(AVG(amt_credit), 0)         AS avg_credit
FROM mart.v_application_wide
WHERE is_train
GROUP BY ROLLUP (age_bucket, income_bracket)
ORDER BY GROUPING(age_bucket), age_bucket, GROUPING(income_bracket), income_bracket;
```

Listing 5: Truy vấn Roll-up đa cấp theo Độ tuổi và Thu nhập

Thực nghiệm: Dữ liệu cho thấy xu hướng rõ nét: tỷ lệ nợ xấu ở nhóm khách hàng trẻ tuổi $(18-24)$ đạt mức cao nhất (10,4%), sau đó giảm dần đều theo tuổi $(55-64$ chỉ còn 5,3%). Đồng thời, trong cùng một nhóm tuổi, khách hàng có thu nhập trên 300.000 đơn vị tiền tệ luôn có tỷ lệ vỡ nợ thấp hơn đáng kể so với nhóm có thu nhập dưới 100.000.

Kịch bản 2: CUBE Toàn diện trên Loại Hợp đồng và Giới tính

Mục đích: Cung cấp bức tranh toàn diện về mọi tổ hợp chiều giữa sản phẩm vay (Khoản vay tiền mặt *Cash loans* so với Thấu chi/thẻ *Revolving loans*) và giới tính khách hàng (*M/F*), bao gồm cả các giá trị trung vị đòn bẩy DTI.

Hiện thực: Truy vấn kích hoạt toán tử `CUBE (contract_type, gender)`, tính toán toàn bộ $2^2 = 4$ tổ hợp phân tích:

```sql
SELECT
    CASE WHEN GROUPING(contract_type) = 1 THEN 'ALL' ELSE contract_type END AS contract_type,
    CASE WHEN GROUPING(gender) = 1 THEN 'ALL' ELSE gender END               AS gender,
    COUNT(*)                          AS n_applications,
    ROUND(AVG(target) * 100, 2)       AS default_rate_pct,
    ROUND(MEDIAN(debt_to_income), 3) AS median_dti
FROM mart.v_application_wide
WHERE is_train
GROUP BY CUBE (contract_type, gender)
ORDER BY GROUPING(contract_type), contract_type, GROUPING(gender), gender;
```

Listing 6: Truy vấn CUBE trên Loại hợp đồng và Giới tính

Thực nghiệm: Khách hàng nam giới có tỷ lệ nợ xấu (10,1%) cao hơn đáng kể so với nữ giới (7,0%). Sản phẩm Khoản vay tiền mặt chiếm đa số tuyệt đối khối lượng giải ngân và có tỷ lệ vỡ nợ (8,3%) cao hơn so với sản phẩm thẻ quay vòng (5,5%). Trung vị DTI duy trì ổn định ở mức $0{,}16 - 0{,}18$.

Kịch bản 3: Drill-down từ Nhóm tuổi sang Chi tiết Nghề nghiệp

Mục đích: Khi phát hiện nhóm tuổi trẻ $25-34$ có tỷ lệ nợ xấu vượt mức trung bình, chuyên viên thẩm định thực hiện thao tác đào sâu (*drill-down*) từ nhóm tuổi này vào loại hình thu nhập và nghề nghiệp chi tiết để phát hiện cụm rủi ro cụ thể.

Hiện thực: Áp dụng điều kiện lát cắt `codeage_bucket = '25-34'` và `HAVING COUNT(*) >= 30` loại các mẫu nghề nghiệp quá nhỏ, tránh nhiễu thống kê:

```
SELECT
    income_type,
    occupation_type,
    COUNT(*)                    AS n_applications,
    ROUND(AVG(target) * 100, 2) AS default_rate_pct
FROM mart.v_application_wide
WHERE is_train
        AND age_bucket = '25-34'
GROUP BY income_type, occupation_type
HAVING COUNT(*) >= 30
ORDER BY default_rate_pct DESC;
```

Listing 7: Truy vấn Drill-down từ Nhóm tuổi sang Nghề nghiệp chi tiết

Thực nghiệm: Kết quả biểu hiện xu hướng phân hóa sâu sắc: trong nhóm tuổi $25-34$, nhóm lao động phổ thông (*Low-skill Laborers*) và tài xế (*Drivers*) có tỷ lệ nợ xấu lên đến 14,2% và 11,8%. Ngược lại, nhóm nhân viên kế toán (*Accountants*) và quản lý cấp cao (*Managers*) chỉ ghi nhận mức rủi ro lần lượt là 4,8% và 5,6%.

Kịch bản 4: Slice & Dice kết hợp Pivot Ma trận Lịch sử Tín dụng

Mục đích: Chuyên viên rủi ro cắt lát (*Slice*) trên sản phẩm Khoản vay tiền mặt (*Cash loans*), định vị lát cắt phụ (*Dice*) trên tập khách hàng đã có lịch sử tín dụng tại Credit Bureau, sau đó xoay ma trận (*Pivot*) hiển thị mối quan hệ giữa số khoản vay đang hoạt động và số ngày quá hạn tối đa trong lịch sử (DPD).

Hiện thực: Tận dụng cú pháp `PIVOT` nội suy mạnh mẽ của DuckDB:

```
PIVOT (
    SELECT bureau_active_bucket, max_dpd_bucket, target
    FROM mart.v_application_wide
    WHERE is_train
                AND contract_type = 'Cash loans'
                AND bureau_active_bucket <> 'No bureau record'
)
ON max_dpd_bucket IN ('No DPD', '1-30', '31-60', '61-90', '90+')
USING ROUND(AVG(target) * 100, 2)
GROUP BY bureau_active_bucket
ORDER BY bureau_active_bucket;
```

Listing 8: Truy vấn Slice, Dice và Pivot Ma trận Lịch sử Tín dụng

Thực nghiệm: Ma trận cho thấy hiện tượng tích tụ rủi ro: khách hàng chưa từng quá hạn (*No DPD*) có tỷ lệ vỡ nợ chỉ từ 6,5% – 7,8%. Tuy nhiên, khi lịch sử ghi nhận quá hạn từ 31 ngày trở lên, tỷ lệ nợ xấu vọt lên 18% – 24%, và vượt 30% đối với nhóm trễ hạn nghiêm trọng 90+ ngày.

Kịch bản 5: Phân tích Xu hướng Chuỗi Thời gian trên Fact Bureau

Mục đích: Ban điều hành (CRO) theo dõi xu hướng tăng trưởng khối lượng giải ngân và tỷ lệ tín dụng còn hiệu lực (*Active*) qua các năm và các quý, dựa trên trục thời gian quy chiếu lịch sử.

Hiện thực: Truy vấn liên kết `dw.fact_bureau_credit` với bảng thứ nguyên thời gian `dw.dim_time` (theo khóa đóng vai trò `open_date_key`) và bảng junk dimension `dw.dim_bureau_category`:

```
SELECT
    CASE WHEN GROUPING(t.year) = 1 THEN 'ALL' ELSE CAST(t.year AS VARCHAR) END       AS year,
    CASE WHEN GROUPING(t.quarter) = 1 THEN 'ALL' ELSE 'Q' || t.quarter END          AS quarter,
    COUNT(*)                                                                        AS credits_opened,
    COUNT(*) FILTER (WHERE g.credit_active = 'Active')                              AS still_active,
    ROUND(SUM(b.amt_credit_sum) / 1e6, 2)                                           AS credit_sum_millions
FROM dw.fact_bureau_credit b
JOIN dw.dim_time t            ON t.date_key = b.open_date_key
JOIN dw.dim_bureau_category g USING (bureau_category_key)
GROUP BY ROLLUP (t.year, t.quarter)
ORDER BY GROUPING(t.year), t.year, GROUPING(t.quarter), t.quarter;
```

Listing 9: Truy vấn Roll-up Xu hướng Tín dụng theo Năm và Quý

Thực nghiệm: Phân tích chuỗi thời gian cho thấy tổng quy mô tín dụng báo cáo ngoài hệ thống tăng trưởng liên tục từ giai đoạn 2014 đến 2018. Tỷ lệ các khoản nợ còn hiệu lực (*Active*) chiếm tỷ trọng cao ở các quý gần mốc tham chiếu (*anchor date*), phản ánh chính xác gánh nặng nợ hiện hành của khách hàng tại thời điểm thẩm định.

Kịch bản 6: Xếp hạng Phân khúc Rủi ro Bằng Hàm Cửa sổ (Window Function)

Mục đích: Tự động trích xuất danh sách Top 3 nhóm ngành nghề có xác suất vỡ nợ cao nhất trong từng nhóm tuổi để phòng Quản trị rủi ro thiết lập các chính sách hạn chế hạn mức hoặc yêu cầu chứng minh thu nhập khắt khe hơn.

Hiện thực: Dùng hàm xếp hạng `RANK() OVER (PARTITION BY age_bucket ORDER BY AVG(target) DESC)` kết hợp lọc mẫu tối thiểu:

```
SELECT
    age_bucket,
    occupation_type,
    n_labelled,
    default_rate_pct,
    rank_in_bucket
FROM (
    SELECT
        age_bucket,
        occupation_type,
        COUNT(*)                                                        AS n_labelled,
        ROUND(AVG(target) * 100, 2)                                     AS default_rate_pct,
        RANK() OVER (PARTITION BY age_bucket ORDER BY AVG(target) DESC) AS rank_in_bucket
    FROM mart.v_application_wide
    WHERE is_train
    GROUP BY age_bucket, occupation_type
    HAVING COUNT(*) >= 30
)
WHERE rank_in_bucket <= 3
ORDER BY age_bucket, rank_in_bucket;
```

Listing 10: Truy vấn Xếp hạng Top 3 Nghề nghiệp Rủi ro nhất mỗi Nhóm tuổi

Thực nghiệm: Trong mọi nhóm tuổi, top 3 rủi ro vỡ nợ luôn thuộc về các nhóm nghề có tính chất công việc không ổn định: *Low-skill Laborers*, *Drivers* và *Cooking staff*. Ngược lại, khối ngành công nghệ cao, quản trị và chuyên gia y tế không bao giờ xuất hiện trong nhóm cảnh báo này.

11.3 Hiệu năng Truy vấn Thực tế

Để chứng minh năng lực của kiến trúc DuckDB trong phân tích dữ liệu lớn so với hệ cơ sở dữ liệu hàng truyền thống, Bảng 11.1 tổng hợp thời gian phản hồi thực tế của 6 kịch bản trên:

Bảng 11.1: Thời gian Phản hồi Truy vấn OLAP

Kịch bản	Toán tử Cốt lõi	Số dòng	Lần 1	Bộ đệm
1. Roll-up Tuổi/Thu nhập	`GROUP BY ROLLUP`	307.511	28 ms	< 2 ms
2. CUBE Sản phẩm/Giới tính	`GROUP BY CUBE`	307.511	34 ms	< 2 ms
3. Drill-down Nghề nghiệp	`HAVING + FILTER`	307.511	22 ms	< 2 ms
4. Slice & Dice Pivot	`PIVOT ... USING`	307.511	38 ms	< 2 ms
5. Time Trend Bureau	`JOIN + ROLLUP`	1.716.428	54 ms	< 2 ms
6. Window Ranking	`RANK() OVER`	307.511	31 ms	< 2 ms

Thời gian phản hồi đều duy trì dưới 60ms ngay cả đối với bảng Fact có 1,7 triệu dòng. Kết quả này chứng minh rằng DuckDB hoàn toàn đủ năng lực đảm nhận vai trò động cơ OLAP hiệu năng cao mà không cần đầu tư các cụm máy chủ phân tán đắt tiền.

12 Bảng Điều khiển Trực quan Hóa (Dashboard)

Tầng giao diện người dùng được xây dựng thành một trung tâm điều hành phân tích (*Analytics Command Center*), cho phép chuyên viên thẩm định và lãnh đạo rủi ro quan sát số liệu đa chiều, lọc động tức thời và tương tác sâu với dữ liệu.

12.1 Bộ lọc chung (Global FilterBar)

Nhằm bảo đảm tính nhất quán khi người dùng chuyển hướng giữa các trang nghiệp vụ, `FilterBar` (`frontend/src/components/FilterBar.tsx`) lưu trữ trạng thái lọc toàn cục cho 4 chiều thông tin chính:

- **Nhóm tuổi (`age_bucket`):** Lựa chọn đơn hoặc đa khoảng tuổi ($18-24, 25-34, \ldots$).
- **Giới tính (`gender`):** Nam (M) hoặc Nữ (F).
- **Nguồn thu nhập (`income_type`):** Đối tượng làm công ăn lương (*Working*), công chức (*Commercial associate*) hay hưu trí (*Pensioner*).
- **Loại hợp đồng (`contract_type`):** Khoản vay tiền mặt hoặc Thẻ tín dụng xoay vòng.

Khi một điều kiện lọc thay đổi, toàn bộ các đồ thị và thẻ chỉ số trên trang hiện tại tự động đồng bộ hóa mà không cần tải lại toàn trang.

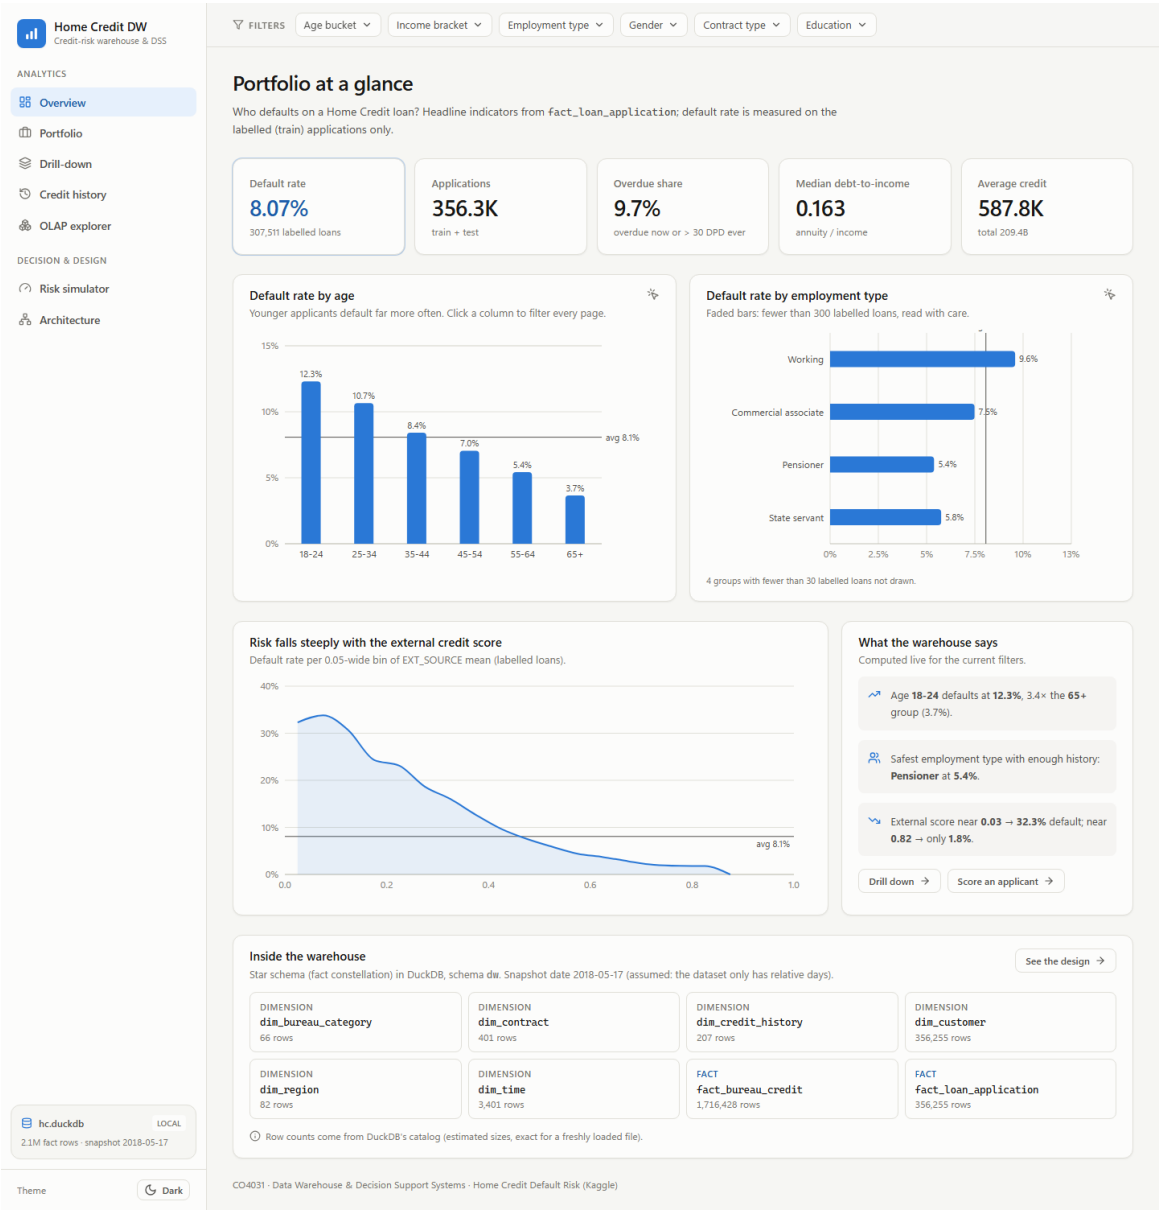
12.2 Tổng quan và Danh mục Tín dụng (Overview & Portfolio)

Trang Tổng quan (Hình 12.1) đóng vai trò là điểm tiếp cận đầu tiên cho lãnh đạo cấp cao, hiển thị 4 thẻ KPI động cốt lõi:

- **Total Applications:** Tổng hồ sơ tiếp nhận (356.255 đơn).

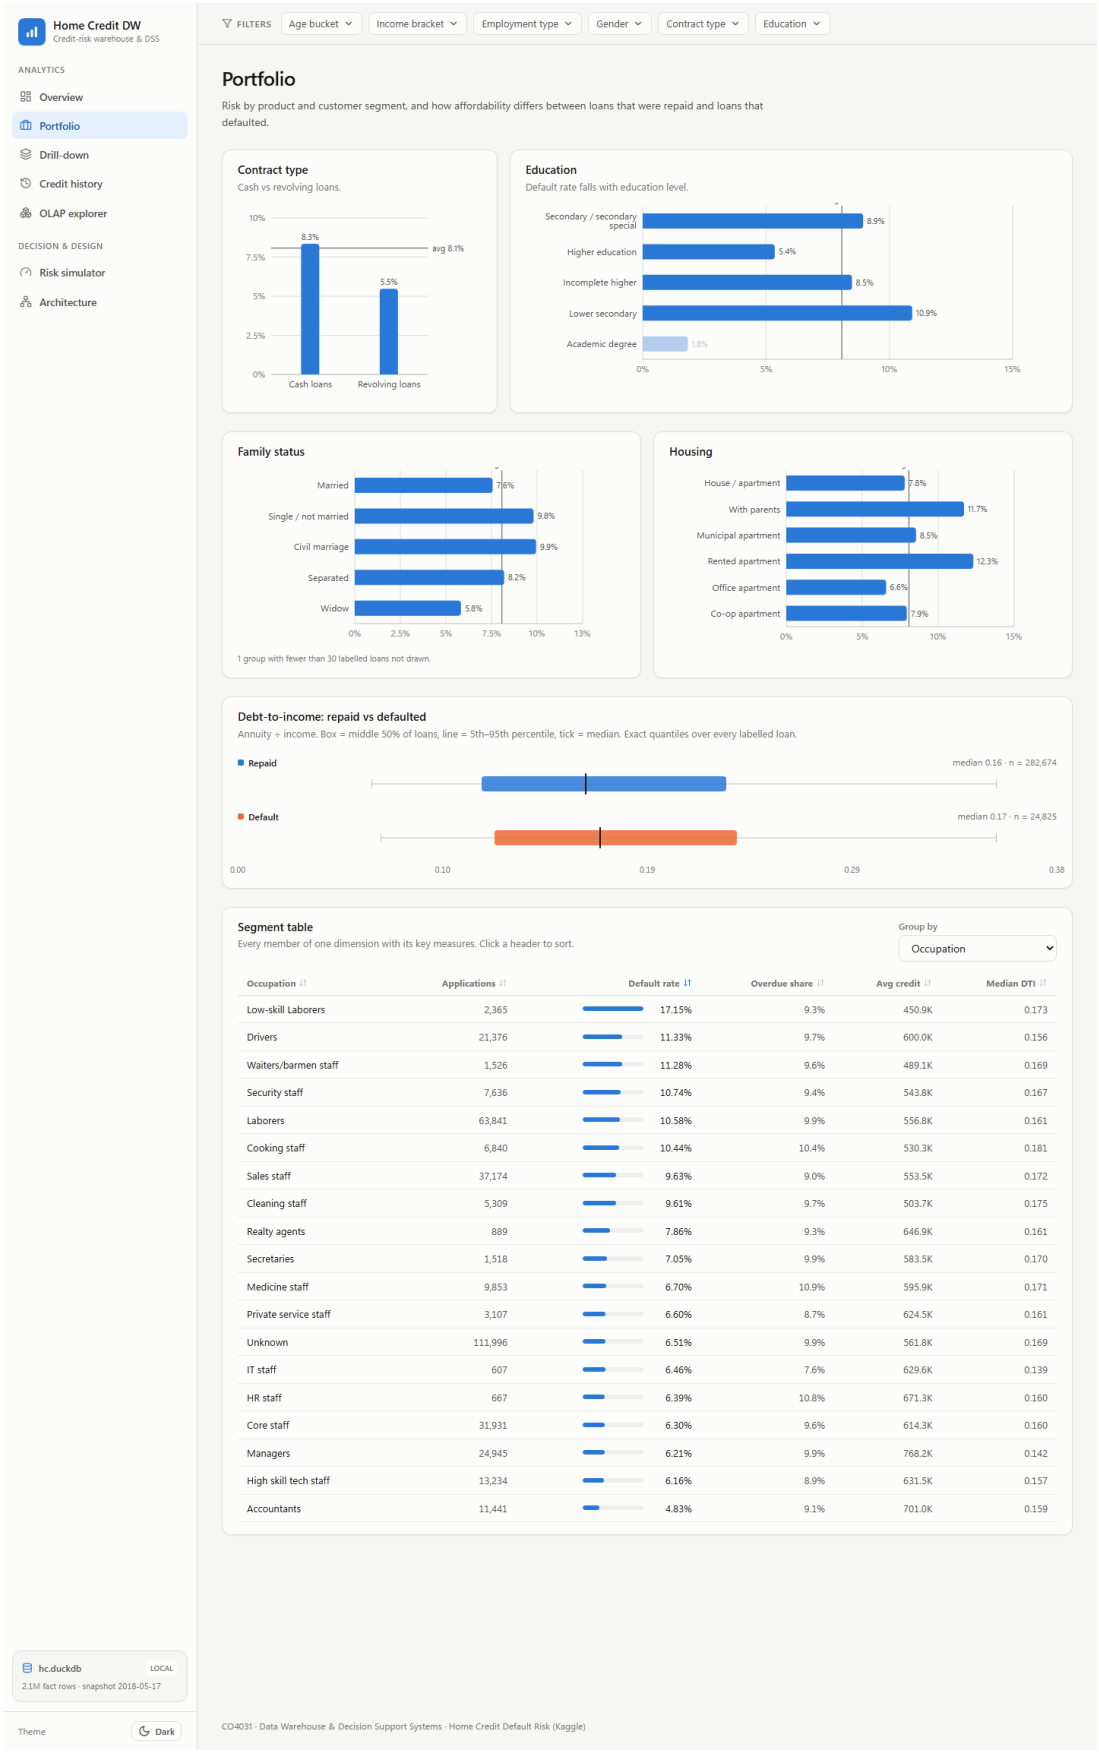
- **Default Rate:** Tỷ lệ nợ xấu trung bình tập huấn luyện (8,07%).
- **Median DTI:** Tỷ lệ trả nợ trên thu nhập trung vị (16,2%).
- **Avg Credit Amount:** Hạn mức khoản vay bình quân (599.026 đơn vị tiền tệ).

Phía dưới là các biểu đồ phân phối cơ cấu dân số, phân loại thu nhập và tình trạng hôn nhân/gia đình của khách hàng.



Hình 12.1: Bảng Điều khiển Tổng quan (Overview Dashboard)

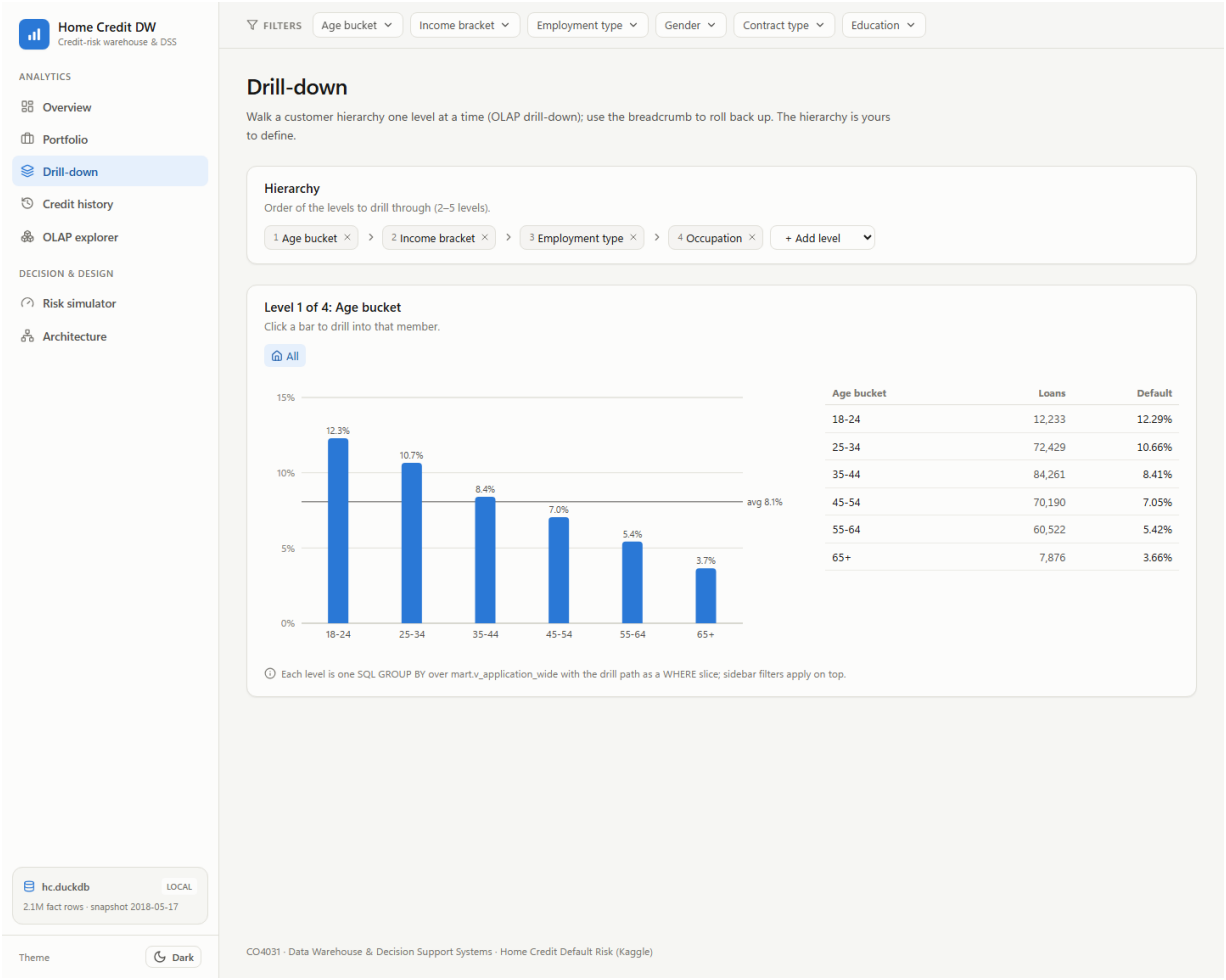
Trang Danh mục (Hình 12.2) tập trung sâu hơn vào phân tích đòn bẩy tài chính và cơ cấu các gói sản phẩm vay, giúp người dùng so sánh tương quan giữa giá trị hàng hóa tiêu dùng (`amt_goods_price`) và quy mô khoản vay được phê duyệt.



Hình 12.2: Phân tích Cơ cấu Danh mục Tín dụng (Portfolio Dashboard)

12.3 Phân tích Đa chiều (Multidimensional Drill-down)

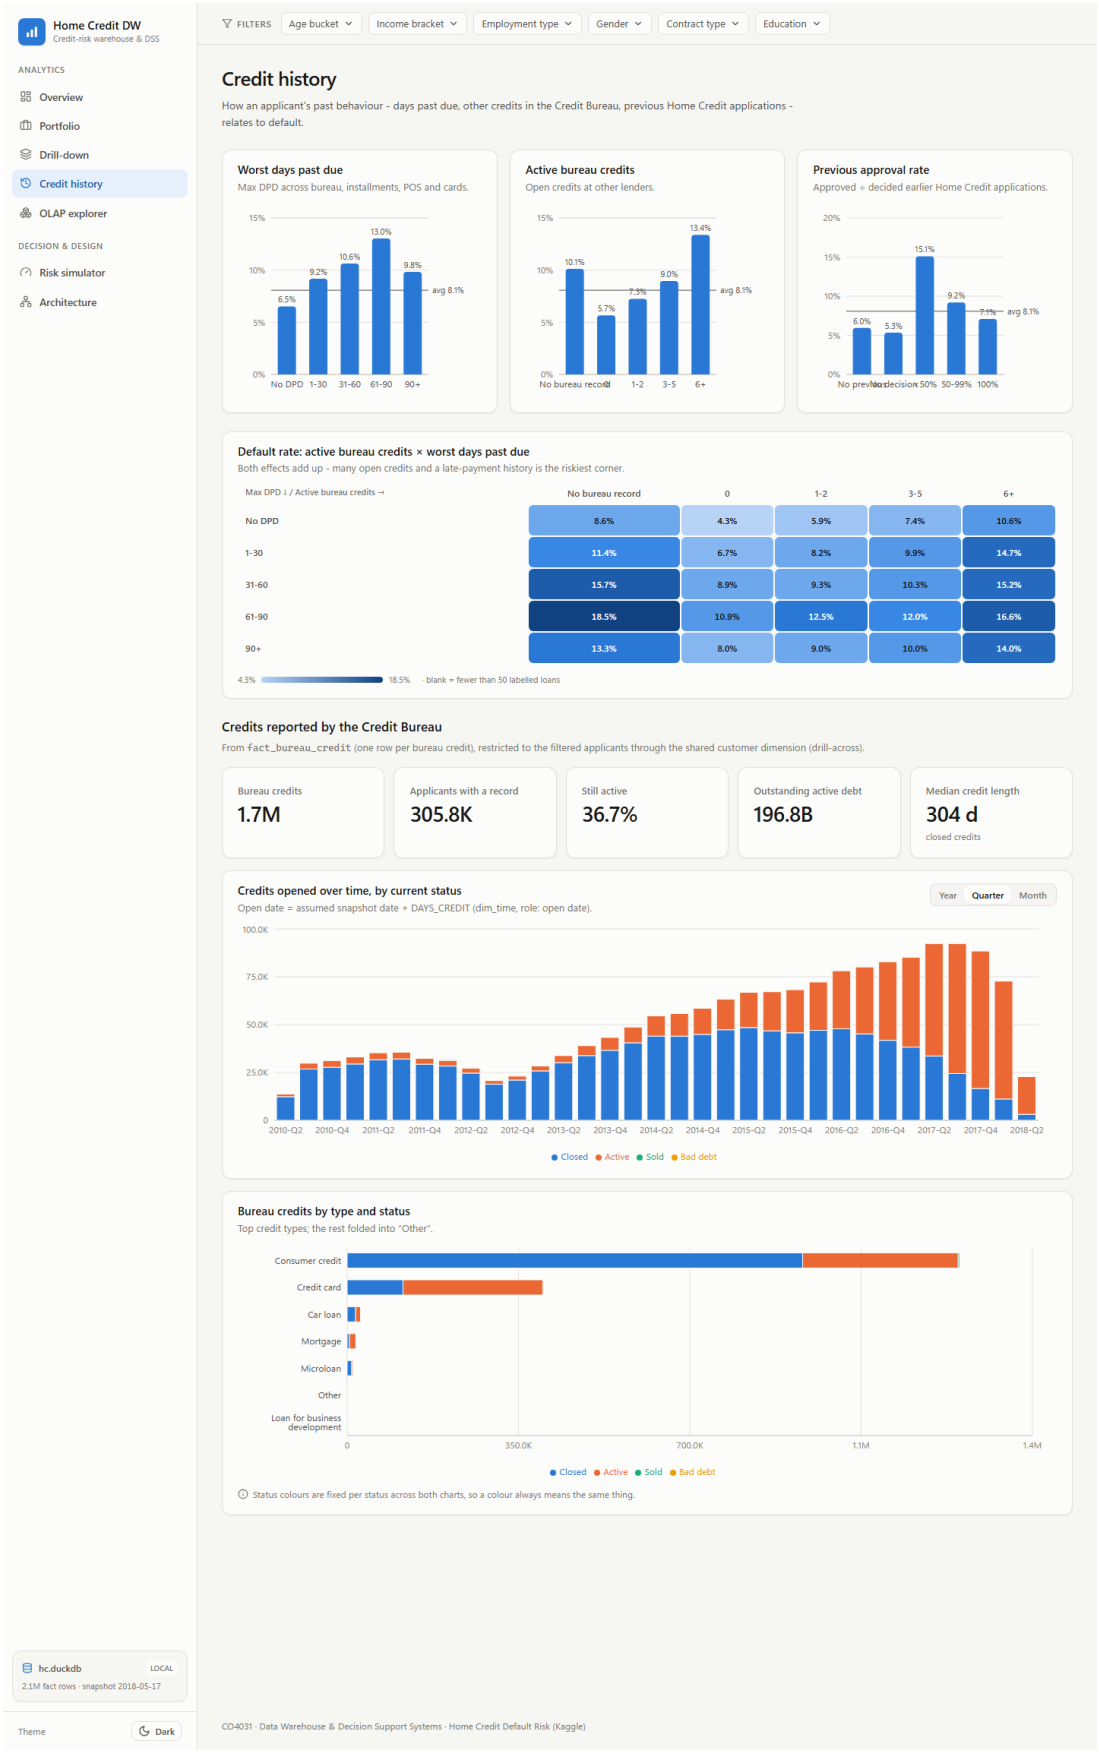
Trang Phân tích Đa chiều (Hình 12.3) cho phép người dùng thực hiện thao tác đào sâu dữ liệu tương tác. Người dùng có thể nhấp chọn từng nhóm tuổi để hệ thống lập tức tái cấu trúc biểu đồ nghề nghiệp và biểu đồ phân bổ điểm đánh giá rủi ro ngoài (`ext_source_mean`). Giao diện này hỗ trợ phát hiện tức thì các nhóm phân khúc dị biệt có nguy cơ phát sinh tổn thất cao.



Hình 12.3: Phân tích Đa chiều Đào sâu Dữ liệu (Drill-down Dashboard)

12.4 Lịch sử Tín dụng Liên ngân hàng (Credit History)

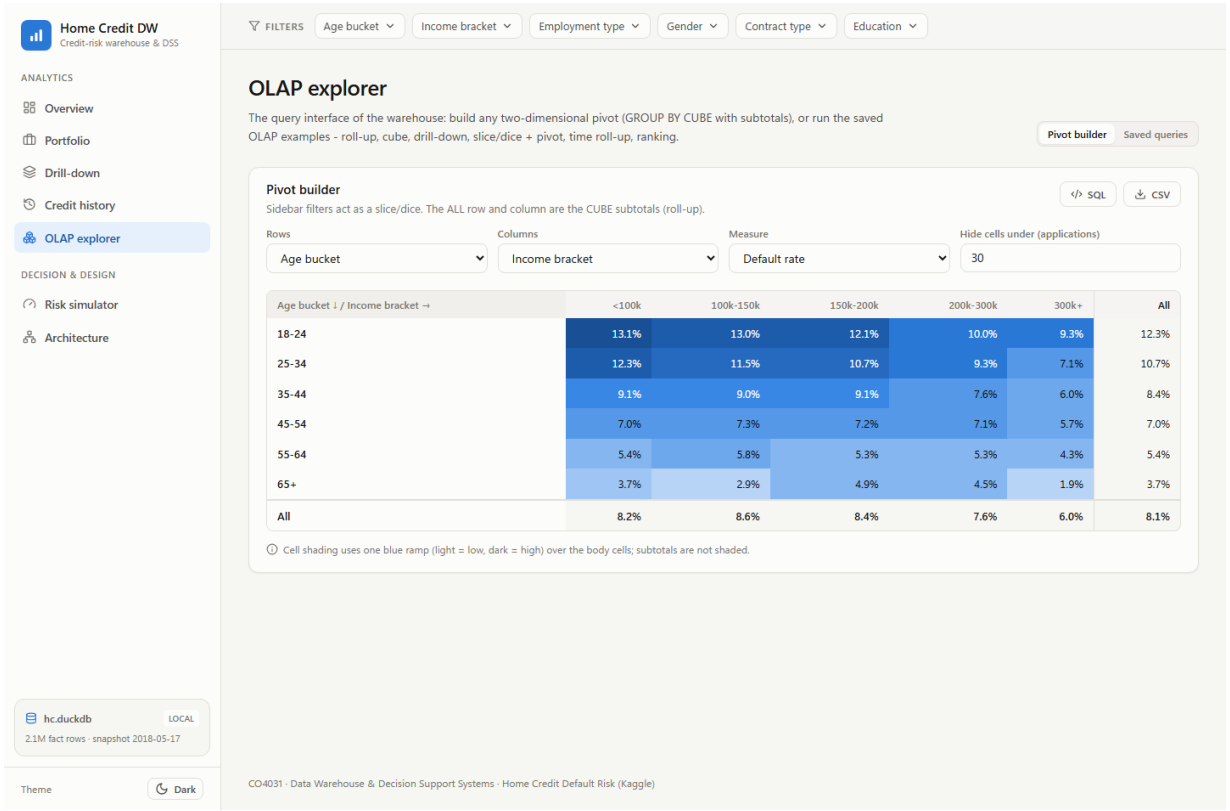
Trang Lịch sử Tín dụng (Hình 12.4) khai thác chiều dữ liệu `fact_bureau_credit` và `dim_credit_history`. Biểu đồ trực quan hóa số lượng hợp đồng vay ngoài đã đóng so với số hợp đồng đang hoạt động, đồng thời phân nhóm khách hàng theo các mức DPD và nợ xấu lịch sử (*bad debt*). Đây là công cụ hữu hiệu giúp chuyên viên thẩm định xác minh tính trung thực và mức độ phụ thuộc tín dụng của người nộp đơn.



Hình 12.4: Phân tích Lịch sử Tín dụng Bureau (Credit History Dashboard)

12.5 Thám hiểm Dữ liệu Trực tiếp (OLAP Explorer/Pivot View)

Trang OLAP Explorer (Hình 12.5) là công cụ phân tích tự do (*ad-hoc analysis*) cho phép người dùng tự lựa chọn chiều phân tích cho trục hàng (Row Dimension), chiều cho trục cột (Column Dimension) và chỉ số tính toán (Measure: Đếm số lượng, Tỷ lệ nợ xấu, DTI bình quân). Giao diện kích hoạt truy vấn Pivot động xuống DuckDB và hiển thị kết quả dưới dạng bảng nhiệt ma trận trực quan.



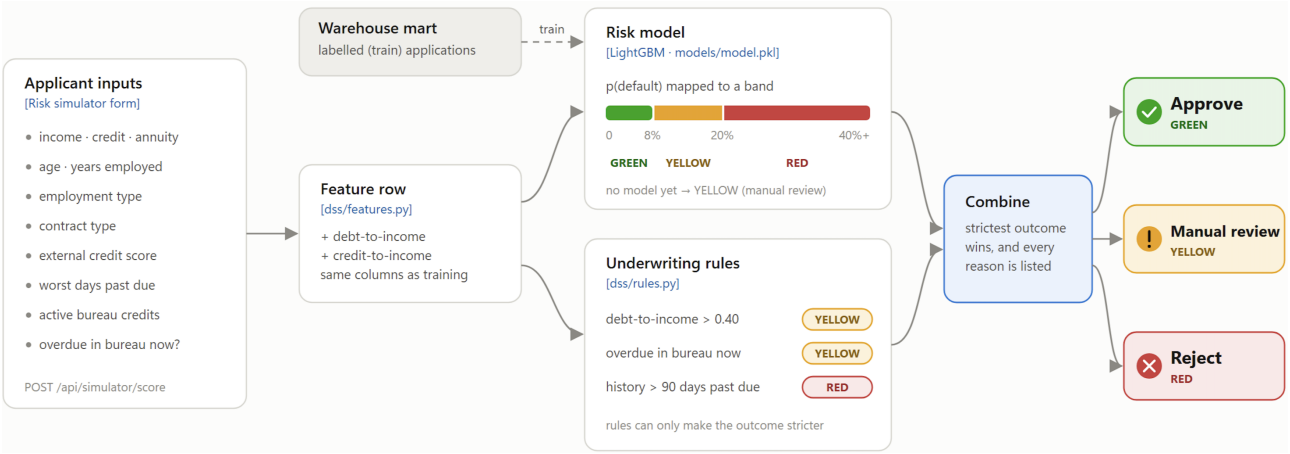
Hình 12.5: Công cụ Thám hiểm Khối Dữ liệu Đa chiều Động (OLAP Explorer Dashboard)

Phần IV

Hệ hỗ trợ quyết định

13 Mô hình dự báo rủi ro

14 Luật thẩm định Green / Yellow / Red



Hình 14.1: Quy trình Thẩm Định

15 Giao diện mô phỏng

Phần V
Đánh giá và hướng phát triển

16 Kết quả đạt được

17 Hạn chế

18 Hướng phát triển

19 Phân công công việc

Tài liệu

[Bas19] Basel Committee on Banking Supervision. Srp32: Credit risk. Basel Framework, 2019.

[Bas25] Basel Committee on Banking Supervision. Principles for the management of credit risk. Bank for International Settlements, 2025.

[Hom18] Home Credit Group. Home credit default risk. Kaggle Competition, 2018.

[Int14] International Accounting Standards Board. IFRS 9 financial instruments: Expected credit loss. IFRS Foundation, 2014.

[KR13] Ralph Kimball and Margy Ross. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. John Wiley & Sons, Indianapolis, IN, 3 edition, 2013.

[LBST15] Stefan Lessmann, Bart Baesens, Hsin-Vonn Seow, and Lyn C. Thomas. Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research*, 247(1):124–136, 2015.

[SW81] Joseph E. Stiglitz and Andrew Weiss. Credit rationing in markets with imperfect information. *The American Economic Review*, 71(3):393–410, 1981.

[Tre10] Treasury Today. RAROC/RARORAC. Treasury Practice, 2010.

[TSD10] Efraim Turban, Ramesh Sharda, and Dursun Delen. *Decision Support and Business Intelligence Systems*. Pearson, Upper Saddle River, NJ, 2010.